

# 場所説明文から地点を推定する Transformer Encoder モデル

高嶋 優快<sup>†</sup>    三林 亮太<sup>†</sup>    山本 岳洋<sup>†</sup>    梶原 光良<sup>††</sup>    澤田 祥一<sup>††</sup>  
大島 裕明<sup>†</sup>

<sup>†</sup> 兵庫県立大学大学院情報科学研究科    〒 651-2197 兵庫県神戸市西区学園西町 8-2-1

<sup>††</sup> 三井住友海上火災保険株式会社    〒 101-8011 東京都千代田区神田駿河台 3-9

E-mail: <sup>†</sup>ad22v035@guh.u-hyogo.ac.jp, <sup>††</sup>threeforest8@gmail.com, <sup>†††</sup>t.yamamoto@sis.u-hyogo.ac.jp,

<sup>††††</sup>{m.kunugihara, shoichi.sawada}@ms-ins.com, <sup>†††††</sup>ohshima@ai.u-hyogo.ac.jp

**あらまし** 本研究は、ある地点を説明している場所説明文と説明されている地点周辺の地図情報から、場所説明文が説明している地点を推測するモデルの作成を目的としている。場所説明文は「学園都市駅とキャンパススクエアの間の地点」や「兵庫県立大学」のような場所を説明する文章である。また、地図情報は、場所説明文にて説明されている地点の周辺情報を OpenStreetMap から取得した地図情報を用いる。本研究では、自然言語処理モデルである Transformer Encoder に地図情報に対応するトークンを追加し、地図情報を入力可能とした。また、地図の大きさを表すトークンを作成し、モデルが地図の大きさを考慮できるようにした。学習データ作成には OpenStreetMap を用いた。OpenStreetMap 内のデータから場所説明文が異なるデータを 4 種類作成し、学習データとした。作成した地図情報を入力可能とした Transformer Encoder に場所案内文と地図情報を入力することで、地点を推定した。

**キーワード** Transformer Encoder, OpenStreetMap, 自然言語処理

## 1 はじめに

近年、全地球の測位システムである GPS (Global Positioning System) が普及している。GPS を用いることによって、現在地が地球上のどこに存在するかを示すことが出来る。この技術によって自身の現在地を座標として他者への伝達が容易になった。GPS は、カーナビゲーションシステムや航空機の位置確認などに応用されている [1] [13] [15]。また、Yahoo!Japan が提供している Yahoo!地図や、Google が提供している Google Maps のような地図情報サービスが普及している。Yahoo!地図、Google Maps のような地図情報サービスを用いることで、ある地点から目的地点への経路を容易に求めることができる。GPS や地図情報サービスを用いると、現在地や目的地点の共有や目的経路の共有ができる。GPS や地図情報サービスを用いると、口頭で場所を説明する場合よりも正確に地点の共有が可能である。また、GPS を用いて歩行者に対してナビゲーションを行う技術 [18] や OpenStreetMap [5] のようなユーザが編集可能であるオープンデータの地図を利用した技術 [19] が存在している。

しかし、GPS や地図情報サービスが普及している現在においても場所を口頭で説明する場合が存在している。例として、タクシーに乗車した際に目的地を運転手に説明する場合や、交通事故を目撃した際に救急車やパトロールカーなどの緊急車両を電話で要請する場合がある。

現在、場所説明文と地図情報から地点を推定するモデルは筆者の確認する限り存在していない。そこで、本研究では場所説明文から、説明されている場所を推定するモデルを作成することを目的とする。

本論文では、続く 2 節で Transformer Encoder に関する研究や場所説明文に関する研究について述べる。次に、3 節でデータ作成の際に用いる OpenStreetMap や問題定義について述べる。4 節では、本研究の問題に対するアプローチについて述べる。5 節で本研究で扱う Transformer Encoder モデルについて示す。6 節では、実験に使用するデータの作成方法について述べる。7 節では、実験方法と結果について述べる。8 節では、実験結果から得られる考察について述べる。9 節で、今後の課題について述べる。

## 2 関連研究

Transformer は Vaswani [9] らによって提案された Encoder-Decoder モデルである。Transformer の特徴は、内部の Attention 機構によってテキスト中の文脈を考慮可能な点である。Attention 機構によって、文章の前後を Transformer の Attention 機構を翻訳以外のタスクに応用できるようにしたモデルとして BERT がある。BERT とは Devlin らによって提案された 12 層の Transformer Encoder から成り立つニューラルネットワークモデルである [2]。BERT に入力するテキストは、あるルールに従って決められた文の構成要素であるトークンに則って分割される。その後、分割後のテキストをベクトル化し、BERT に入力をする。

一般的に Transformer は大量のテキストデータを用いて事前学習する [14]。テキストデータを用いて事前学習されたモデルをさらに別のデータにてファインチューニングを行うと、タスクに特化したモデルの作成が可能になる [4]。壹岐ら [20] は、既存のモデルに対して追加学習を行うことの有用性を示した。

藤井ら [17] は自然言語で示された場所の説明文の分析の際に、単語ではなく句構造によって分析を行った。Winter ら [11] は外出している人に、「今どこにいるか教えてください」という質問で現在地を尋ねると、75%の人が住所やランドマーク、空間的な関係を使って自分の位置を説明することを示した。大佛らは [16]、紙媒体とインターネット広告サイトの渋谷駅を出発点とした案内図で、掲載されるランドマークは、視認が容易な建築面積が大きい建物より、曲がり角にある建物のように、目的地と経路の位置関係を考慮して抜粋されていることを示している。Noordzij ら [7] は、人はルート・ディスクリプションとサーベイ・ディスクリプションでは、サーベイ・ディスクリプションの方が、詳細な地図をイメージができることを明らかにした。Taylor ら [8] は、説明文を作成する地点の周辺環境によって書きやすい説明文の視点が変化する可能性を示した。Lovelace ら [6] は、文章で行う良い道案内とは、どのようなものか調査し、複雑なルートを説明する場合、長文の道案内の方が、人からの評価が高くなることを示した。

Gao [3] は、画像のラベルの曖昧さを利用した Deep Label Distribution Learning を提案し、マルチラベル分類やセマンティックセグメンテーションのタスクに対する認識性能が向上することを示した。Wang ら [10] は、Label Distribution Learning は分類モデルとして扱われる際の矛盾を解決するために新たな手法を提案した。Zhang ら [12] はマルチラベル学習をパラダイムの形式化、学習アルゴリズム、関連する学習設定の観点から検証し、あるラベルがほかのラベルに与える影響は同じとは限らないことを示した。

### 3 データと問題定義

本節ではデータ作成の際に用いる OpenStreetMap についてや、本研究の問題定義について示す。本研究で地図情報の取得には OpenStreetMap を用いる。OpenStreetMap とは誰でも自由に地図情報を扱えるオープンデータの地理情報を作成するプロジェクトである。OpenStreetMap は地上の地点に対してタグ付けを行い、地点の情報をタグで表現する。タグはキーと値という二つの値を用いて構成されている。キーは地点の特徴や地点のカテゴリを表す。値はキーで指定された地物の特徴やカテゴリに関しての詳細な情報を記載する。従って OpenStreetMap の要素にタグ付けを行うことで地点の特徴を示すことが出来る。OpenStreetMap 内のデータにはノード、ウェイ、リレーションという三種類のデータ要素が存在している。ノードは緯度と経度を定義することで地上にある地点を表すデータ構造である。ウェイはノードの順序のある集合となっており、連続した線分を示すデータ構造である。リレーションは、ノードとウェイや他のリレーションの位置関係を示すデータ構造である。ノード、ウェイ、リレーションには特定の地物や特徴を表すタグが存在する場合がある。

本研究の問題定義は

- 入力
  - 場所説明文

- OpenStreetMap から取得した地図情報
  - 出力
    - 地図上の区画
- としている。

## 4 アプローチ

本節では本研究で使用するモデルについて述べる。本研究では日本語の Wikipedia の記事で事前学習された Transformer Encoder モデル<sup>1</sup> を使用する。このモデルにはトークンが 32,000 種類存在している。そこで、地図情報に対応するトークンを新たに作成し、モデルのトークンを増加させる。地図情報に対応するトークン作成時に OpenStreetMap の wiki<sup>2</sup> に記載されている情報を用いる。本研究では地図の区画の 1 辺の大きさのことをスケール、スケールの大きさを示すトークンのことをスケールトークンと記載する。OpenStreetMap の wiki は html で記載されている。html 内の情報から、キーと値を入手し、(キー) = (値) という形式のトークンを 1,263 種類作成した。また、スケールトークンを 8 種類作成する。また、区画内に何も地図情報が存在しないことを示すトークンを 1 種類作成する。新たに作成した合計 1,272 種類のトークンと、存在している 32,000 種類のトークンを合わせた 33,272 種類のトークンをモデルに入力できるようにする。

## 5 Transformer Encoder を用いた位置推定手法

### 5.1 モデルの概観

本節では本研究で用いるモデルの概観について示す。本研究では図 1 に示す Transformer Encoder を用いて学習する。このモデルは、場所説明文部、地図部、推定器で構成される。場所説明文部には場所説明文を入力する。また、地図部には地図情報を入力する。入力された場所説明文、地図情報から得られた出力を用いて、推定器で正解地点を推測する。

4 節で作成したトークンに従って、Transformer Encoder の入力ベクトルの次元を増加させる。なお、本論文では道案内文を入力する部分を場所説明文部、地図の情報を入力する部分を地図部と表現する。

### 5.2 場所説明文部

本節では、場所説明文を入力する場所説明文部について述べる。場所説明文部にはスケールトークンと場所説明文を入力する。図 2 に示すように場所説明文の前に 5.6 節で作成するスケールトークンを入力する。なお、場所説明文部に入力できるトークンの最大長は 128 個である。もし、場所説明文の入力するトークン数が 128 個以下であった場合、入力するトークン数が 128 個になるように場所説明文の末尾に 0 を追加し、入力トークン数の調整を行う。その後、トークンをそれぞれ 33,272 次元のベクトルに変換し、変換したベクトルを場所説明文部に入力する。

1 : cl-tohoku/bert-base-japanese-whole-word-masking

2 : [https://wiki.openstreetmap.org/wiki/JA:Map\\_Features](https://wiki.openstreetmap.org/wiki/JA:Map_Features)

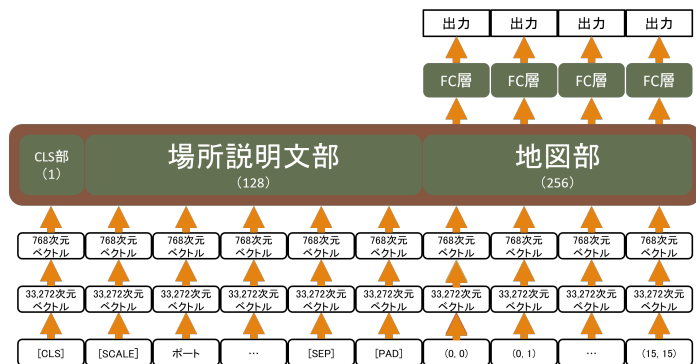


図 1 本研究における Transformer Encoder モデルの概要

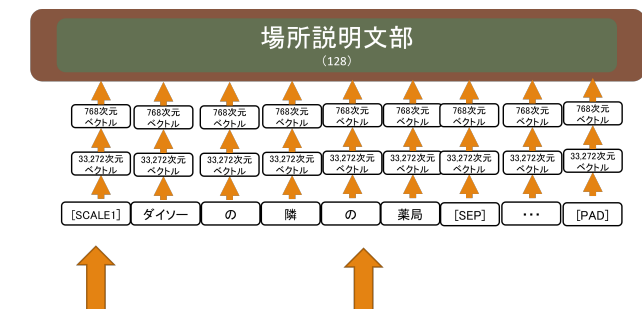


図 2 場所説明文部への入力

### 5.3 地図部

本節では地図部について記述する．本研究で使用するモデルの地図部の入力するベクトルの総数は 256 個である．Open-StreetMap から取得した地図情報を図 3 のように縦、横をそれぞれ 16 分割し、合計 256 個の区画に分割する．分割した区画一つ一つに対して区画内の情報を表すベクトルを作成する．区画内の情報を表すベクトルの作成方法を図 4 に示す．

例として、図 4 のように、ある区画内に「サイゼリア」というレストラン、「ローソン」というコンビニエンスストアが含まれているとする．この場合、区画内の情報は以下に示す 4 つである．

- レストランを表すトークン
- コンビニエンスストアを表すトークン
- 「サイゼリア」というテキスト情報
- 「ローソン」というテキスト情報

この区画の情報はレストランを表すトークン、コンビニエンスストアを表すトークン、「サイゼリア」というテキストに対応するトークン、「ローソン」というテキストに対応するトークンが 1 となる 33,272 次元のベクトルで表される．なお、本研究では、同じ区画内に同じ種類の情報が複数回登場しても、その情報に対応するトークンの値を 1 とする．

作成した 33,272 次元のベクトルを Embedding 行列を利用し、768 次元のベクトルにする．その後、768 次元のベクトルをベクトル内で登場したトークン数で割ることで地図ベクトルを取得する．




図 3 縦横 16 分割後の地図

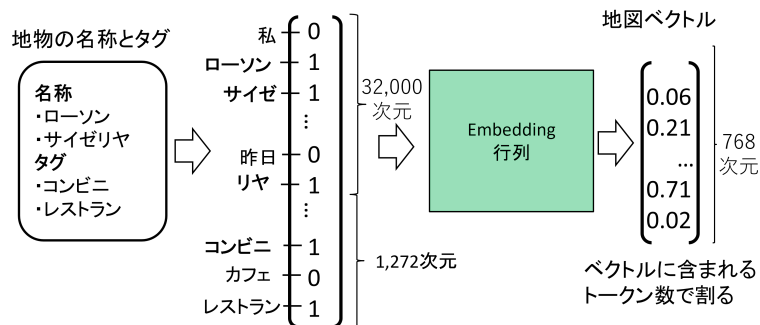


図 4 地図部に入力するベクトルの例

### 5.4 Token Embedding

本節では Token Embedding について示す．本研究ではモデルにスケールトークン、場所説明文、地図情報を入力する．5.2 節で示したように場所説明文部に入力されるベクトルは one-hot ベクトルである．しかし、5.3 節で示したように地図部の入力ベクトルは one-hot ベクトルではない場合がある．地図部の特徴を算出したのちに、場所説明文部の特徴に地図部の特徴を追加する．場所説明文部と地図部の特徴の要素とトークンの要素の和を求めることで Token Embedding を行っている．

### 5.5 推定器

本節では本モデルの推定器について述べる．モデルの場所説明文部でスケールトークンと場所説明文、地図部に地図情報を入力する．その後、モデルの地図部から出力されたベクトルを取得する．地図部の出力ベクトルを全結合層に入力する．全結合層から出力された推定の値から、正解区画を推定する．本研究では、出力された推定の値が最も大きい地点に対応する区画を正解区画と推測する．




図 5 Label Distribution Learning 適応前の地図の評価




図 6 Label Distribution Learning 適応後の地図の評価

## 5.6 スケールトークン

本節ではスケールトークンについて記載する。本研究の学習に用いるデータには複数種類の縮尺の地図が存在する。今回はスケールの大きさによって推測を変更できるようにスケールの情報をモデルに入力する。スケールをトークンで表すためにスケールが 5m, 10m, 20m, 40m, 80m, 160m, 320m, 640m であることを表すスケールトークンを 8 種類用意した。また、スケールトークンをモデルに入力するときには場所説明文の前に入力する。

## 5.7 Label Distribution Learning

本節では地図部の重みの算出に用いた Label Distribution Learning について記載する。地図の区画を正解不正解でのみ判断すると図 5 のように正解地点のみが評価される。この評価方法では、予測した区画が、正解または不正解の判定しか出来ず、正解区画と予測区画の距離を考慮できない。そこで、本研究では予測区画の正誤以外に予測区画と正解区画の距離を考慮するために Label Distribution Learning を用いた。今回は正解区画付近を評価するために、正解区画を中心に二次元のガウス分布の確率密度関数を作成し、図 6 のように正解地点を中心に評価ができるようにした。今回二次元の正規分布の標準偏差は 2 としている。

## 5.8 学習方法（ロスについて）

本節では学習方法について記載する。本研究では、モデルの地図部から出力されたベクトルのみ取得する。地図部からの出力ベクトルを全結合層に入力し、推論された値を取得する。推論された値を用いて交差エントロピー誤差を算出する。算出した交差エントロピー誤差を逆伝播し、学習を行う。

## 6 OpenStreetMap データベースからの学習データの作成

本節では OpenStreetMap から作成する学習データについて

述べる。

### 6.1 ランドマーク名称データ

本節ではランドマーク名を場所説明文とするデータの作成方法について述べる。ランドマークデータは、場所説明文に

- 兵庫県立大学神戸商科キャンパス
- ポートピアホテル
- ファミリーマート

のように建物の名前のみを用いる。OpenStreetMap から作成したトークンのうち、ランドマークのみで場所が説明できる地点を表すトークンを 188 種類入手にて選択する。選択した 188 種類のトークンに対応する OpenStreetMap のデータを 552,259 件取得する。取得したデータから無作為に 10,000 件のデータを取得する。この 10,000 件のデータを用いてランドマーク名データを作成する。取得したデータ座標を中心に半径 1,280m 以内に存在する地点のデータを取得する。一つのデータに対して、地図の 1 区画の大きさが 5m, 10m, 20m, 40m, 80m である 5 種類の地図を作成する。また、場所説明文の文章として OpenStreetMap に記録されている名前を用いる。

### 6.2 隣データ

本節では隣データの作成方法を示す。隣データとは、場所説明文が

- ダイソーの隣の薬局
- ファミリーマートの近くのガソリンスタンド

のような表現を用いるデータを示す。6.1 節で選択した 188 種類のトークンに対応する 552,259 件のデータをから 10,000 件ランダムに取得する。また、6.1 節で選択した 188 種類のトークンに対応する日本語を決定する。ランダムに取得した 10,000 件のデータに記録されている座標を正解地点とする。正解地点を中心に、半径 1,280m 内の地点を入手する。その後、正解地点との距離が 1m 以上かつ 30m 以内の地点を調べる。このとき、地点の持っている情報が、188 種類のトークンに含まれているのかを調べ、含まれているならば、候補地とする。

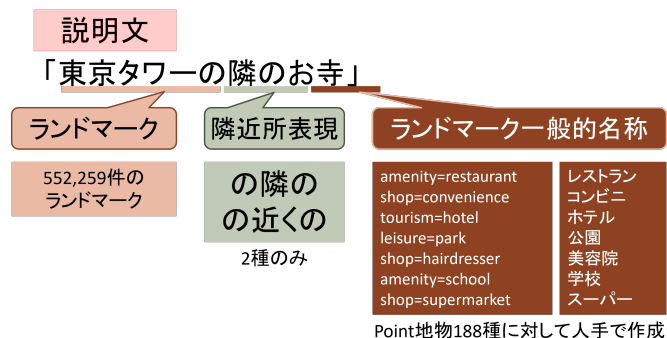


図 7 作成される隣データの文章

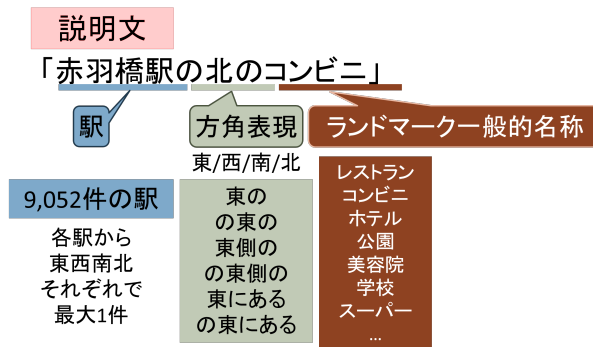


図 9 作成される方角データの文章




図 8 作成される交通地点データの文章

また、場所説明文の表現を作成するために、「の近くの」と「の隣の」という表現をランダムで選択した。このデータの場所説明文として図 7 のように「(候補地点のデータ名) (「の近くの」もしくは「の隣の」 (正解地点のトークンに対応する日本語))」という文章を作成する。

### 6.3 交通地点データ

本節では交通地点データの作成方法を示す。交通地点データとは、場所説明文が

- 三井のリハウスの近くの交差点
- こばやしフルーツの前の横断歩道
- 小野薬品工業の近くのバス停
- 肉の山形屋の前の踏切

のような表現を用いるデータを示す。

6.1 節で選択した 188 種類のトークンに対応する 552,259 件のデータをから 10,000 件ランダムに取得する。ランダムに取得した 10,000 件のデータに記録されている座標を候補地点とする。また、交差点、横断歩道、バス停、踏切に対応する 4 種類のトークンを取得し、それぞれに対応する日本語を決定する。正解地点を中心に、半径 1,280m 内の地点を入手する。作成するトークンを決め、ランドマークと一番近い地点を決め、その地点を正解地点とする。このデータの場所説明文として図 8 のように「(候補地点のデータ名) (「の近くの」, 「の隣の」, 「の前の」 (正解地点のトークンに対応する日本語))」という文章を作成する。

### 6.4 方角データ

本節では方角データの作成方法を示す。方角データとは、場所説明文が以下のような表現を用いているデータのことである。

- 姫路駅南の郵便局
- 東京駅の北にあるホテル
- 練馬駅の北のカフェ

データ作成にあたり、駅に対応するトークンを取得し、そのトークンに当てはまる地点を 9,052 件抽出する。また、対象となるランドマークのタグを 40 件決定する。ランダムに取得した駅のデータに対してその点を中心とした地図情報を取得する。その際に中心地点から 30m 以内に登場したランドマークのタグに対応するデータを記録する。中心地点から 30m の地点に出現した地点と中心地点の成す角度を算出する。その後、駅から 30m 以上 150m 以内の地点の角度を算出する。角度と距離の条件を満たす地点を正解地点とする。正解地点を中心に、半径 1,280m 内の地点を入手する。作成するトークンを決め、ランドマークと一番近い地点を決め、その地点を正解地点とする。このデータの場所説明文として図 9 のように「(駅の名前) (「の南の」, 「南の」, 「の北にある」 (正解地点のトークンに対応する日本語))」という文章を作成する。

### 6.5 データ拡張

本節では本研究で行うデータ拡張について示す。本研究では、作成したデータに対してデータ拡張を行っている。地図情報を取得する際に正解地点から 1,280m 以内の地点を取得する。場所説明文が中心に存在するような縦 31 分割、横 31 分割されている地図を作成する。

横軸、縦軸に対してそれぞれ乱数を発生させ、学習時に縦 31 分割、横 31 分割されている地図の中からランダムで 16×16 の地図を抽出する。

6.1 節であるデータを中心を持つ地図の中からランダムに正方形の地図を取得する際に、広めの地図を取得している。学習の際にランダムに地図の範囲を決定し、正解地物が存在する区画を変えることで、データ拡張を行っている。

## 7 実 験

本節では作成したデータを用いて Transformer Encoder を



表 1 学習したモデルのテスト結果

テストデータ	正解率	予測区画と正解区画の距離
テストデータすべて	0.850	0.584
ランドマーク名称データ	0.932	0.327
隣データ	0.808	0.778
交通地点データ	0.832	0.568
方角データ	0.824	0.703

学習させる方法と学習結果について記載する。

6.1 節, 6.2 節, 6.3 節, 6.4 節にて作成した学習データ 35,000 件を用いて学習を行った。学習データの詳細は以下のようになっていた。

- ランドマーク名称データ：10,000 件
- 隣データ：10,000 件
- 交通地点データ：10,000 件
- 方角データ：5,000 件

それぞれのデータを無作為に 8:1:1 に分割し、データを合わせることで訓練データ、検証データ、テストデータとして扱う。

ファインチューニングしたときの学習条件は以下のよう指定した。

- batch 数：16
- 学習率：5e-5
- Dropout 率：0.1
- patience:5
- epoch：条件により早期終了

学習した際の学習曲線を図 10 に示す。また、ファインチューニングしたモデルの予測した区画と正解の区画との距離を算出した。学習したモデルのテストデータに対する正解率と予測区画と正解区画の距離の平均を表 1 に示す。表 1 に示されるランドマーク名称データの予測区画と正解区画の距離を表すヒストグラムを図 11 に、隣データの予測区画と正解区画の距離を表すヒストグラムを図 12 に、交通地点データの予測区画と正解区画の距離を表すヒストグラムを図 13 に、方角データの予測区画と正解区画の距離を表すヒストグラムを図 14 に示す。

図 11～図 14 より、正解区画と予測区画が異なってもあまり距離が離れていないことがわかる。また、表 2 より、テストデータに対する推測結果についてスケールが 80m のテストデータに比べてスケールが 5m のテストデータの正解率が高くなっている。

## 8 考 察

### 8.1 テストデータに対する推測

本節では、7 節で得られた実験結果から考えられる考察について示す。

表 2 ではスケールが 80m のテストデータに比べてスケールが 5m のテストデータの正解率が高くなっている。この結果になった原因として、地図情報を地図部に入力する際に区画内の情報がスケールが 80m のデータの方がスケールが 5m のデータよりも区画内の情報を多く持っていることが考えられる。区




図 10 すべてのデータを用いた学習結果




図 11 モデルのランドマーク名称データに対する推測結果




図 12 モデルの隣データに対する推測結果

画内の地図情報を多く持っていることにより、地図部のベクトルが複雑になっており、推定結果が悪くなったのではないかと考えられる。

### 8.2 モデルの推測結果

本節では、7 節で得られた学習モデルの推測結果について示す。図 15 は場所説明文として「ソフトバンクショップ」という文章が入力された例、図 16 は場所説明文として「セブンイレブンの近くの横断歩道」という文章が入力された例である。なお、正解区画を黒色、予測区画を赤色、推測の値が大きい区画を黄色で表示している。

表 2 学習したモデルのスケールごとの正解率

テストデータ	80m の正解率	40m の正解率	20m の正解率	10m の正解率	5m の正解率
テストデータすべて	0.820	0.825	0.857	0.870	0.893
ランドマーク名称データ	0.843	0.889	0.948	0.989	0.993
隣データ	0.751	0.723	0.814	0.838	0.901
交通地点データ	0.871	0.872	0.828	0.799	0.774
方角データ	0.882	0.764	0.772	0.822	0.888




図 13 モデルの交通地点データに対する推測結果




図 14 モデルの方角データに対する推測結果

図 15 の推測結果は正解区画の周辺に対して推測の値が大きくなっている。このような結果になった理由として、5.7 節で適応した Label Distribution Learning が影響していると考えられる。また、図 16 の推測結果は正解区画から離れている地点を正解であると予測してしまっている。このような結果になった理由として、正解区画の周辺以外にも「セブン-イレブン」というテキストが存在しており、その周辺の地点を推測してしまっただことが考えられる。また、正解区画、予測区画の周辺に推測の値が高い区画が存在しており、5.7 節で適応した Label Distribution Learning が影響している。したがって地図内に複数存在しているテキストが場所説明文に用いられていると正解区画の推測が難しいと考察できる。

## 9 まとめと今後の課題

本節ではまとめと今後の課題を示す。本研究では、スケール




図 15 「ソフトバンクショップ」という場所説明文に対する推測結果



図 16 「セブン-イレブンの近くの横断歩道」という場所説明文に対する推測結果

トークン、場所説明文、地図情報を入力することで、場所説明文を推定するモデルの作成を行った。今後の課題として、正解区画の推定精度の向上や、学習データの種類を増加、「セブン-イレブン」のような地図情報に複数個記録されている地点やテキストの判別が挙げられる。

## 謝 辞

本研究は JSPS 科研費 JP21H03775, JP21H03774, JP21H03554, JP22H03905 の助成を受けたものです。ここに

記して謝意を表します。

## 文 献

- [1] Robert J Aughey. Applications of GPS technologies to field sports. *International Journal of Sports Physiology and Performance*, Vol. 6, No. 3, pp. 295–310, 2011.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 4171–4186, 2019.
- [3] Bin-Bin Gao, Chao Xing, Chen-Wei Xie, Jianxin Wu, and Xin Geng. Deep Label Distribution Learning with Label Ambiguity. *CoRR*, Vol. abs/1611.01731, , 2016.
- [4] Suchin Gururangan, Ana Marasovic, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A Smith. Don't stop pretraining: Adapt language models to domains and tasks. In *Proceedings of the 2020 Annual Meeting of the Association for Computational Linguistics*, pp. 8342–8360, 2020.
- [5] Mordechai Haklay and Patrick Weber. OpenStreetMap: User-Generated Street Maps. *IEEE Pervasive Computing*, Vol. 7, No. 4, pp. 12–18, 2008.
- [6] Kristin L. Lovelace, Mary Hegarty, and Daniel R. Montello. Elements of good route directions in familiar and unfamiliar environments. In *Spatial Information Theory Cognitive and Computational Foundations of Geographic Information Science*, pp. 65–82, 1999.
- [7] Matthijs L. Noordzij and Albert Postma. Categorical and metric distance information in mental representations derived from route and survey descriptions. *Psychological Research*, Vol. 69, No. 3, pp. 221–232, 2005.
- [8] Holly A Taylor and Barbara Tversky. Perspective in spatial descriptions. *Journal of memory and language*, Vol. 35, No. 3, pp. 371–391, 1996.
- [9] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Proceedings of the 2017 International Conference on Neural Information Processing Systems*, pp. 6000–6010, 2017.
- [10] Jing Wang and Xin Geng. Classification with Label Distribution Learning. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, IJCAI-19*, pp. 3712–3718. International Joint Conferences on Artificial Intelligence Organization, 7 2019.
- [11] Stephan Winter, Allison Kealy, Matt Duckham, Abbas Rajabifard, Kai-Florian Richter, Tim Baldwin, Lesley Stirling, Lawrence Cavedon, and Daniela Richter. Starting to talk about place. In *Infrastructure Engineering - Research Publications*, 2011.
- [12] Min-Ling Zhang and Zhi-Hua Zhou. A Review on Multi-Label Learning Algorithms. *IEEE Transactions on Knowledge and Data Engineering*, Vol. 26, No. 8, pp. 1819–1837, 2014.
- [13] 中村英夫, 川口有一郎, 清水英範, 巖綱林, 柴崎亮介. 地理情報システムを用いたシステム分析的都市計画. 土木学会論文集, Vol. 1993, No. 476, pp. 67–76, 1993.
- [14] 柴田知秀, 河原大輔, 黒橋禎夫. BERT による日本語構文解析の精度向上. 言語処理学会第 25 回年次大会発表論文集, pp. 205–208, 2019.
- [15] 神田準史郎, 脇本浩司, 田中 聡澄夫. GPS 情報を利用した歩行者向け実写道案内システムの検討. 情報処理学会研究報告高度交通システム (ITS) , pp. 102–103, 2005.
- [16] 大佛俊泰. 歩行経路案内図生成のための地図構成要素抽出モデルについて. 日本建築学会計画系論文集, Vol. 70, No. 593, pp. 117–122, 2005.
- [17] 藤井晴行, 青木義次. ことばによる経路案内の統語論的分析. 日本建築学会計画系論文集, Vol. 66, No. 549, pp. 199–206, 2001.
- [18] 良太郎福井, 洋白川, 由香歌川, 寛重野, 謙一岡田, 温松下. 携帯電話における歩行者ナビゲーション情報の表示方法に関する提案と評価. 情報処理学会論文誌, Vol. 44, No. 12, pp. 2968–2978, 2003.
- [19] 森本萌心, 松崎良美, 吉村麻奈美, 滝澤友里, 松岡淳子, 村山優子. OpenStreetMap を用いた最短経路案内付きアクセシビリティマップの開発. 情報処理学会第 80 回全国大会講演論文集, pp. 519–520, 2018.
- [20] 壹岐太一, 金沢輝一, 相澤彰子. 学術分野に特化した事前学習済み日本語言語モデルの構築. 研究報告情報基礎とアクセス技術, Vol. 2020, No. 4, pp. 1–6, 2020.