

複数地域の同時学習が可能な未訪問 Out-Of-Town POI 推薦手法

壺内 陸友[†] 原 隆浩[†] 米川 慧^{††} 春田秀一郎^{††}

[†] 大阪大学大学院情報科学研究科 〒565-0971 大阪府吹田市山田丘1番5号

^{††} 株式会社 KDDI 総合研究所 〒356-8502 埼玉県ふじみ野市大原二丁目1番15号

E-mail: [†]{tsubouchi.rikuto,hara}@ist.osaka-u.ac.jp, ^{††}{ke-yonekawa,sh-haruta}@kddi.com

あらまし 近年、位置情報 SNS による行動データの蓄積に伴い、ユーザの好みに沿った場所を推薦する POI 推薦が盛んに研究されている。一般的な POI 推薦手法は、ユーザの日常的な行動をもとに居住地周辺の POI を推薦するのに対し、居住地外の推薦に特化した Out-Of-Town POI 推薦が存在する。しかし、ユーザは未訪問の地域について POI 情報を必要とするケースが多いにもかかわらず、既存手法は訪問先地域でも一定数の訪問シーケンスを必要とする手法や特定の2地域間のみに特化した手法など、汎用性に欠けるものが多い。そこで、本研究では、ユーザが未訪問の複数地域に対して POI の推薦が可能な手法 OTP-KGAT を提案する。

キーワード POI 推薦, Out Of Town, Cross City

1 序 論

近年、位置情報を用いた SNS (Social Networking Service) の普及に伴い、ユーザの行動データが大量に蓄積されている。その活用先として、ユーザの嗜好に沿った POI (Point Of Interest) を推薦する POI 推薦が盛んに研究されている。高精度の POI 推薦は、ユーザの個別のニーズに合った POI の情報を提示することを可能にし、企業の効果的な集客施策に貢献する。

POI 推薦は、地理的距離のバイアスを大きく受けることが知られている。ユーザは内容が魅力的と感じる POI に対しても地理的な距離が大きすぎる場合、訪問に至らないことが多い。したがって、過去のインタラクションをもとに POI 推薦モデルを学習した場合、暗示的にユーザの日常的な居住地周辺の行動から嗜好を捉え、居住地周辺の POI を推薦するようにモデルが学習される。また、このような地理的距離のバイアスを大きく受ける POI 推薦の特徴を活かし、明示的に地理的距離を推薦モデルに組み込む手法も多く研究されている。

これらの手法は、ユーザの日常的な行動に対しては高い精度の推薦が可能であることが示されている。しかし、ユーザは日常的に行動する地域にある POI の情報は既知である場合が多いため、推薦システムから新たな情報を必要とするのは旅先など未訪問の非居住地 (Out-Of-Town) に訪問する場合が大半である。居住地 (Home-Town) 周辺の POI を高くスコアリングするように学習したモデルは、Out-Of-Town における POI の推薦の精度が大幅に低下する。これに対して、Out-Of-Town での POI 推薦 (Out-Of-Town POI 推薦) に特化した手法の研究が行われている。

旅行先など、Out-Of-Town で POI の情報を必要とする状況において、ユーザが過去にその地域に訪問していることは非常に稀である。しかし、既存手法では、Out-Of-Town でも一定数の過去の訪問シーケンスを必要とする場合が多く、実際のユースケースとは必ずしも合致しない。また、既存手法は特定の2

地域間の一方向の訪問に限定した手法が大半である。このような手法では、複数地域間の Out-Of-Town POI 推薦を行う場合、異なる複数のモデルを学習する必要があり、導入コストが高い。これらの課題に対し、CAPTOR [9] は、ユーザの Home-Town における訪問シーケンスを入力とすることで、Out-Of-Town POI 推薦が可能であり、複数地域の同時学習が可能なモデルである。しかし、このモデルは訪問先地域は未知であるというタスク設定のもと、Home-Town に近い Out-Of-Town に属する POI を推薦する手法である。そのため、一般的な POI 推薦手法と同様に、遠方の地域の POI の推薦は想定していない。従って、この手法では、訪問先に悩むユーザに対して有益な推薦リストを提示することはできない。

上記の問題を解決することを目的として、本研究では、訪問先地域は既知であると想定し、未訪問の地域においても有効な POI 推薦が可能である Out-Of-Town POI 推薦手法 OTP-KGAT を提案する。本研究は、実際のユースケースに合致した Out-Of-Town POI 推薦に取り組む最初の研究である。提案手法は、ユーザの Home-Town における訪問シーケンスを入力とし、地域特有の影響を考慮した特徴転移層を学習することで、学習時に登場しない新規ユーザに対しても Out-Of-Town POI 推薦を可能とする。

本研究は、地域間の地理的距離により、ユーザの訪問行動における Out-Of-Town の傾向の度合が変化することに着目する。本論文では、地域を都道府県レベルで定義するが、実際にユーザの行動範囲は県境に関係なく、シームレスに広がっている。したがって、Home-Town と隣接する Out-Of-Town に訪問した際、ユーザは Out-Of-Town 的な訪問傾向よりも Home-Town 的な訪問傾向を示す可能性がある。ユーザの Home-Town 的な訪問傾向は前述の地理的距離的のバイアスを受けるため、訪問先の地域のうち Home-Town に近いエリアの POI に訪問する可能性が高い。このような点から、我々は地理的位置関係を考慮せず Out-Of-Town 特有の嗜好を捉えた POI のスコアリングと地理的位置関係を考慮し日常的な嗜好を捉えた POI のスコア

リングの2つを同時に行い、居住地と訪問先地域の位置関係によりスコアを使い分けるアプローチを提案する。

さらに、データが疎であることが多い Out-Of-Town POI 推薦環境下において、POI 表現間の相互作用を強めた学習が可能なマスク入力学習およびユーザ表現作成方法を提案する。

OTP-KGAT は実世界のサービス上で収集されたデータセットにおいて、既存手法を上回る推薦精度を達成した。

本論文の以下では、第2章で関連研究について紹介する。第3章で本論文におけるデータ構造と概念について定義する。第4章では提案手法 OTP-KGAT について説明し、第5章で実験の詳細設定及び評価とその結果の考察を行う。最後に第6章で本研究のまとめと今後の課題について述べる。

2 関連研究

2.1 Out-Of-Town POI 推薦

Out-Of-Town POI 推薦では、Out-Of-Town におけるユーザのインタラクションは極めて疎であるという制約がある。この制約下で、2つの地域間の違い（訪問傾向ドリフト）を捉える必要がある。1つ目はユーザレベルの訪問傾向ドリフトである。ユーザは Home-Town において勤務先やスーパーなど日常的な訪問が中心の傾向を示すのに対し、Out-Of-Town では、観光地を中心としたイレギュラーな訪問傾向となる。このような課題に対し、PR-UIDT [2] は、ユーザ表現の一部を Home-Town と Out-Of-Town で共有し、残りを独立してそれぞれの地域で学習することで、地域間で転移可能なユーザの潜在的特徴を共有しつつ、ユーザレベルの地域間ドリフトに対応する MF ベースのモデルを提案している。また、PR-UIDT では、比較的密な Out-Of-Town を居住地とするローカルユーザの行動データを用いて、Out-Of-Town における POI 表現の学習を補助することで、Out-Of-Town での疎なデータ環境でも強固な学習が行える仕組みを組み込んでいる。TRAINOR [8] は、特定の2地域間において Home-Town でのユーザ表現から Out-Of-Town でのユーザ表現への転移層を学習することで、一部の Out-Of-Town での訪問シーケンスをもつユーザを用いて Home-Town の訪問シーケンスのみしか持たないユーザにも適応可能な推薦モデルの構造を提案している。

地域間の訪問傾向ドリフトの2つ目は群衆レベルの訪問傾向ドリフトである。同じようなサービスを展開する POI であっても、類似したサービスを展開する POI が周囲に多い場合と少ない場合ではそれぞれの POI が利用される度合いが異なる。また、例えば京都のような神社・仏閣を多く有する地域と、大阪のような商業施設を多く有する地域では、同じカテゴリの POI であっても、地域におけるその POI の群衆的な注目度合いは大きく異なる。これに対し、HOPE [6] や CAPTOR は、群衆レベルでの嗜好をモデリングし、スコアリングに組み込むことで、疎なデータ制約下での推薦精度を向上させつつ、群衆レベルの訪問傾向ドリフトに対応する機構を提案している。

既存手法の多くは、以下の2つの問題点の両方もしくはそのどちらかを有している。1つ目は Out-Of-Town でも一定数の

訪問シーケンスを必要とする点である。PR-UIDT や HOPE がこれに該当する。実際のユースケースでは、Out-Of-Town の訪問先地域の POI を調べる状況において、ユーザがその地域に過去に訪問していないことがよくある。このようなケースにおいて、これらの手法は適切な推薦を行うことが不可能である。2つ目は特定の2地域間の一方向に限定したタスク設定であることである。TRAINOR がこれに該当し、複数都市間で Out-Of-Town POI 推薦を行う環境を整えるためには、すべての地域のペアに対してそれぞれの方向でモデルを学習する必要がある、導入コストが極めて高い。

それに対し、CAPTOR はこれら2つの既存手法の問題点を解決した初めての手法である。しかし、CAPTOR は訪問先地域は未知であるというタスク設定のもと、ユーザの Out-Of-Town 訪問は Home-Town 周辺の地域で起こりやすいという仮定において設計されたモデルであるため、本質的には遠方地域の POI について適切にスコアリングを行うことができない。

2.2 KGAT

KGAT [7] は協調知識グラフを用いた Graph Attention Network ベースの推薦システムである。従来の協調フィルタリング手法は、インタラクションが疎であるデータ環境下において、ユーザやアイテムを十分に表現できず、性能が低下する。これに対し、FM [5] を代表として、ユーザやアイテムの属性情報を用いた教師あり学習により、情報を補完するアプローチが研究されてきた。しかし、従来の手法では、高次の属性情報の共有関係を捉えることができなかった。そこで、KGAT はアイテムの属性情報とユーザのインタラクションを、属性情報の対応関係でエッジを結んだ知識グラフとインタラクションの有無でユーザとアイテムにエッジを結んだ協調グラフからなる、協調知識グラフとして表現した。協調知識グラフに対し、再帰的に Graph Attention を繰り返すことで、高次の属性情報の共有関係を捉えることを可能とし、Attention の重みで畳み込みを行うことで、効果的な情報伝播を行った。

本研究では、Out-Of-Town 地域においてユーザのインタラクションが非常に疎であることを想定し、POI の属性情報を効果的に利用することを目的として、POI 表現および地域表現の獲得に KGAT を用いた。

3 定義

本章では、本論文におけるデータ構造と概念について定義した後、本論文が設定するタスクについて定義する。

定義1 (地域) 地域とは地理的に区切られた空間的なエリアである。本論文では地域を r として表現する。本論文では地域として、日本における都道府県を用いている。

定義2 (POI) POI とは地理的な位置に関連する空間的なアイテムである。本論文では POI を v として表現する。また、POI v が属する地域を r_v として表現する。

定義3 (ユーザ) 本論文ではユーザを u として表現する。また、学習に用いたユーザ全体の集合を $\mathcal{U} = \{u_i\}_{i=1}^{|\mathcal{U}|}$ とする。




図1 協調知識グラフ

定義4 (Home-Town) 本論文では各ユーザーに学習期間における訪問回数が最も多い地域を Home-Town とする。

定義5 (訪問シーケンス) 本論文ではユーザー u の学習期間における訪問シーケンスを $\vec{c} = \{v_1, v_2, \dots, v_n\}$ として定義する。また、ユーザーが訪問した POI のうち、ユーザーの Home-Town r_{Home} 内の POI とそれ以外の地域の POI を分割し、それぞれ Home-Town 訪問シーケンス \vec{c}_h および Out-Of-Town 訪問シーケンス \vec{c}_o として定義する。

定義6 (協調知識グラフ) 協調知識グラフは図1のように、知識グラフとユーザー-POI インタラクション2部グラフの2つで構成される。知識グラフは POI ノードとエンティティノードをエッジで結んだ2部グラフである。エンティティには地域と POI カテゴリを用いる。各 POI ノードは自身が属する地域のエンティティノードと地域所属関係エッジで結ばれ、自身が分類される POI カテゴリエンティティノードにカテゴリ分類関係エッジで結ばれる。本論文ではこの知識グラフを用途に応じた2つの協調知識グラフに拡張する。1つ目は、各ユーザーについて訪問シーケンス $\vec{c} = \{v_1, v_2, \dots, v_n\}$ に応じてユーザーノードと POI ノードをインタラクション関係エッジで結んだ HT 協調知識グラフである。このグラフでは、Home-Town から地理的位置関係を考慮したノード表現を獲得するために活用される。2つ目は、各ユーザーについて Out-Of-Town 訪問シーケンス \vec{c}_o に応じてユーザーノードと POI ノードをインタラクション関係エッジで結んだ OT 協調知識グラフである。このグラフでは、地理的位置関係を可能な限り排除したノード表現を獲得するために活用する。

また本論文は以下の2つのタスクへの適応を想定する。

タスク定義 A ($u \in \mathcal{U}$) モデルの学習に用いたユーザー $u \in \mathcal{U}$ のうち、学習データ作成期間に地域 r に未訪問のユーザーについて、テストデータ作成期間における地域 r での POI 訪問を予測する。地域 r に属するすべての POI についてスコアを算出し、Top k (上位 k 個) の POI を推薦結果とする。

タスク定義 B ($u^* \notin \mathcal{U}$) モデルの学習に登場しないユーザー $u^* \notin \mathcal{U}$ について、テストデータ作成期間における地域 r での POI 訪問を予測する。地域 r に属するすべての POI についてスコアを算出し、Top k の POI を推薦結果とする。

4 提案手法

提案手法 OTP-KGAT の概要を図2に示す。OTP-KGAT は大きく2つの部分からなる。図2の上半分は OT 協調知識グラフをもとに Out-Of-Town 特有の嗜好を捉えてスコアリングを行う部分であり、下半分は地理的な位置関係を考慮し日常的な嗜好を捉えてスコアリングを行う部分である。

4.1 KGAT 層

4.1.1 ノード表現学習

KGAT 層では、OT 協調知識グラフ \mathcal{G}_{OT} および HT 協調知識グラフ \mathcal{G}_{HT} のそれぞれに基づいて、各ノードの表現を学習する。ノード i の表現を以下のように定義する。

$$\mathbf{e}_i = \mathbf{e}_{Sep,i} \parallel \mathbf{e}_{Share,i} \quad (1)$$

ここで、 $\mathbf{e}_{Sep,i} \in \mathbb{R}^{d/2}$ は各グラフで独立して学習する表現であり、 $\mathbf{e}_{Share,i} \in \mathbb{R}^{d/2}$ は2つのグラフ間の対応する実体のノードについて表現のパラメータを共有しながら学習する部分である。また、 \parallel はベクトルを連結する操作である。ユーザーや POI は Out-Of-Town と Home-Town で特徴にドリフトが起こるものの、本質的には同一の実体である。したがって、双方で転移可能な特徴が存在する。このように表現の一部を共有しながら、双方の損失が同時に最適化されるように学習することで、共有する表現で転移可能な情報を学習することができる。これにより、比較的疎である Out-Of-Town のインタラクションを用いた OT 協調知識グラフに対して、比較的密な Home-Town のインタラクションを用いて知識を転移することが可能となる。

各ノードの表現は、まず協調知識グラフ学習に多く応用される翻訳原理に基づいた手法である TransR [3] をもとに学習される。ここで、協調知識グラフ上のノード h から他のノード t に対して、ノード接続関係 r でエッジが結ばれている期待スコア $g(h, r, t)$ を以下の式で定義する。

$$g(h, r, t) = \|\mathbf{W}_r \mathbf{e}_h + \mathbf{e}_r - \mathbf{W}_r \mathbf{e}_t\|_2^2 \quad (2)$$

ここで、 $\mathbf{W}_r \in \mathbb{R}^{k \times d}$ は、関係 r に関する変換行列、 $\mathbf{e}_h, \mathbf{e}_t \in \mathbb{R}^d$ および $\mathbf{e}_r \in \mathbb{R}^k$ は、それぞれ h, t のノード表現および r のエッジ表現である。このスコアを用いて、以下のペアワイズ損失を OT 協調知識グラフおよび HT 協調知識グラフのそれぞれについて最小化することで、ノード表現を学習する。

$$\mathcal{L}_{KG,OT} = \sum_{(h,r,t,t') \in \mathcal{T}_{OT}} -\ln \sigma(g(h, r, t') - g(h, r, t)) \quad (3)$$

$$\mathcal{L}_{KG,HT} = \sum_{(h,r,t,t') \in \mathcal{T}_{HT}} -\ln \sigma(g(h, r, t') - g(h, r, t)) \quad (4)$$

ここで、 $\mathcal{T}_{OT} = \{(h, r, t, t') | (h, r, t) \in \mathcal{G}_{OT}, (h, r, t') \notin \mathcal{G}_{OT}\}$, $\mathcal{T}_{HT} = \{(h, r, t, t') | (h, r, t) \in \mathcal{G}_{HT}, (h, r, t') \notin \mathcal{G}_{HT}\}$ である。OT 協調グラフのノード表現は Out-Of-Town 訪問のみに依存して学習するため、ユーザーの Out-Of-Town 特有の嗜好を反映した表現として学習され、HT 協調グラフのノード表現は比較的密な Home-Town 訪問を重点的に学習するため、ユーザーの日常的嗜好を反映した表現として学習される。

4.1.2 Graph Attention Aggregator

次に、獲得したノード表現を用いて、Graph Attention ベースの情報伝播により、推薦タスクに用いる POI 表現および地域表現を獲得する。Aggregator では、まず注目ノードと隣接したノードの表現を Attention の重みで足し合わせた、情報伝播表現を算出する。ノード h に関する情報伝播表現は以下の式で定義される。

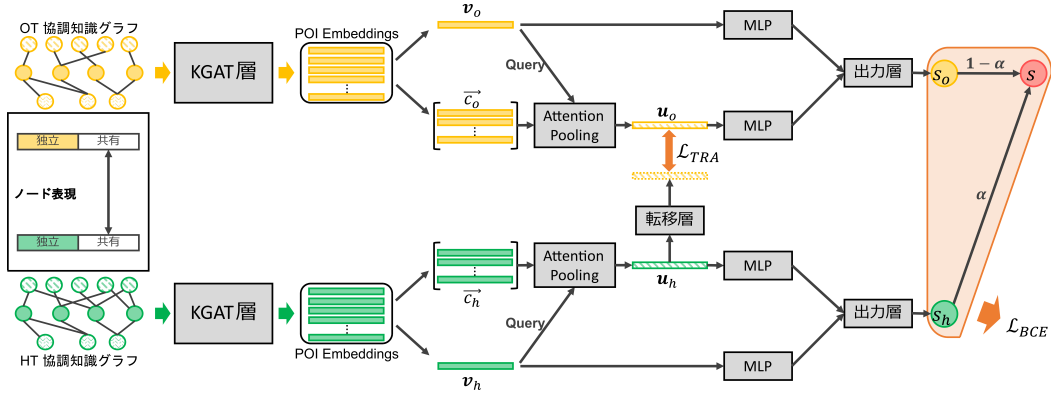


図 2 提案手法の概要

$$\mathbf{e}_{\mathcal{N}_h} = \sum_{(h,r,t) \in \mathcal{N}_h} \pi(h,r,t) \mathbf{e}_t \quad (5)$$

ここで、 \mathcal{N}_h は、ノード h に関する全ての隣接ノードとのトリプレット集合である。 $\pi(h,r,t)$ は Attention の重みであり、以下の式で算出される。

$$\pi'(h,r,t) = (\mathbf{W}_r \mathbf{e}_t)^T \tanh((\mathbf{W}_r \mathbf{e}_h + \mathbf{e}_r)) \quad (6)$$

$$\pi(h,r,t) = \frac{\exp(\pi'(h,r,t))}{\sum_{(h,r',t') \in \mathcal{N}_h} \exp(\pi'(h,r',t'))} \quad (7)$$

したがって、情報伝播表現 $\mathbf{e}_{\mathcal{N}_h}$ は、始点終点のノード表現とその接続関係のエッジ表現に依存する重みで推薦に重要なノードに着目し、周辺ノード表現を足し合わせた表現であるといえる。また、Aggregator は以下の関数により、情報伝播表現を、その時点のノード表現に足し合わせる。

$$f_{Agg}(\mathbf{e}_h, \mathbf{e}_{\mathcal{N}_h}) = \text{LeakyReLU}(\mathbf{W}_1(\mathbf{e}_h + \mathbf{e}_{\mathcal{N}_h})) + \text{LeakyReLU}(\mathbf{W}_2(\mathbf{e}_h \odot \mathbf{e}_{\mathcal{N}_h})) \quad (8)$$

ここで、 \odot はアダマール積である。この操作を、 l 回繰り返すことで、 l ホップの隣接関係を考慮したノード表現が獲得可能である。 l ホップ目のノード表現 $\mathbf{e}_h^{(l)}$ は以下の式で算出できる。ここで、 $\mathbf{e}_h^{(0)} = \mathbf{e}_h$ である。

$$\mathbf{e}_h^{(l)} = f_{Agg}(\mathbf{e}_h^{(l-1)}, \mathbf{e}_{\mathcal{N}_h}^{(l-1)}) \quad (9)$$

このようにして算出した、 L ホップのノード表現の連結により、推薦に用いる POI 表現および地域表現を獲得する。ノード h が POI ノードであるとき、その POI の表現は以下の式で定義される。

$$\mathbf{v} = \mathbf{e}_h^{(0)} || \dots || \mathbf{e}_h^{(L)} \quad (10)$$

また、ノード h が地域ノードであるとき、その地域の表現は以下の式で定義される。

$$\mathbf{r} = \mathbf{e}_h^{(0)} || \dots || \mathbf{e}_h^{(L)} \quad (11)$$

これにより、高次の接続関係を考慮した、POI および地域の表現が獲得可能である。また、 \mathbf{v}_o および \mathbf{r}_o を OT 協調知識グラフ由来の表現、 \mathbf{v}_h および \mathbf{r}_h を HT 協調知識グラフ由来の表現として表記する。

4.2 Attention Pooling 層

Attention Pooling 層では、ユーザの訪問シーケンスから、スコアを算出する対象 POI に応じた動的な重みによる足し合わせにより、ユーザ表現を作成する。

4.2.1 ユーザ表現作成

ユーザの訪問シーケンスが $\vec{c} = \{v_1, v_2, \dots, v_n\}$ 、スコアを算出する対象 POI が v_i であるとき、ユーザ表現は以下の関数で算出される。

$$f_{Atten}(\mathbf{v}_i, \vec{c}) = \sum_{j=1}^n \alpha_j \mathbf{v}_j \quad (12)$$

$$\alpha_j = \frac{\exp(\mathbf{W}_q \mathbf{v}_i (\mathbf{v}_j)^T)}{\sum_{k=1}^n \exp(\mathbf{W}_q \mathbf{v}_i (\mathbf{v}_k)^T)} \quad (13)$$

ここで、 \mathbf{W}_q は、クエリ変換行列である。これにより、ユーザが過去に訪問した POI に対して、動的に注目度合いを変更したユーザ表現を作成することが可能である。このユーザ表現作成手法では、既存の表現学習によりユーザ表現を獲得する手法に比べて2つの利点がある。1つ目は、スコアリングに必要な情報のみに注目できる点である。スコアリングを行う上で、最も重要な情報はユーザがその POI と類似した POI に頻繁に訪問しているかとユーザがその POI に相反する POI に頻繁に訪問していないかである。既存の手法では、いずれの POI に対しても単一のユーザ表現に基づいてスコアを算出するため、ユーザ表現内には、その店舗とのスコアの算出に必要な情報も含まれ、スコア算出におけるノイズに繋がると考えられる。2つ目は、訪問シーケンスのみで新規ユーザにも推薦可能となる点である。既存の手法では、ユーザの訪問シーケンスが得られても、学習時に存在しないユーザに対して推薦を行うためには、ユーザ表現獲得のためモデルを再学習する必要がある。これに対し、提案手法のユーザ表現作成手法は、必要な情報のみに注目した、新規ユーザにも適応可能な手法である。

4.2.2 マスク入力学習

本研究では、BERT [1] の Masked LM 学習を参考としたマスク入力学習を提案する。提案手法は、時系列を考慮しない訪問シーケンスから、同一期間での POI 訪問を予測するタスクにより学習を行うため、正例の POI が必ずユーザの訪問シーケンス内に存在してしまう。テスト時には、新たな地域での訪問を想定しているにも関わらず、学習データに過学習した場合、

訪問シーケンス内に同一の POI があるかどうか非常にセンシティブなスコアになってしまう恐れがある。

そこで、学習時において f_{Atten} によりユーザ表現を算出する前に、ユーザの訪問シーケンス内におけるスコアを算出する対象 POI v_i と同一 POI をマスクする操作を追加する。マスク操作を行った訪問シーケンスは以下のように表現できる。

$$\vec{c}_{Mask} = \{v_j | v_j \in \vec{c}, v_j \neq v_i\} \quad (14)$$

これにより、正例に対する学習は、周辺の訪問から実際に訪問した POI のスコアを予測するタスクとすることができ、過学習を抑制し、より POI 間の相互関係を高めた学習が可能となる。この操作によりユーザの訪問シーケンスのバリエーションも増加するため、より多様な入力を基にした学習が可能となる。

OT 協調知識グラフをもとに算出した表現集合と Out-Of-Town 訪問シーケンス \vec{c}_o を用いて作成する、POI 表現 v_o に対するユーザ表現は以下の式で算出される。

$$u_o = f_{Atten,OT}(v_o, \vec{c}_{o,Mask}) \quad (15)$$

また、HT 協調知識グラフをもとに算出した表現集合と Home-Town 訪問シーケンス $\vec{c}_h, Mask$ を用いて作成する、POI 表現 v_h に対するユーザ表現は以下の式で算出される。

$$u_h = f_{Atten,HT}(v_h, \vec{c}_h, Mask) \quad (16)$$

4.3 スコアリング層

4.3.1 スコア算出

獲得したユーザ表現および POI 表現をさらに表現力の高い表現に変換するため、それぞれに M 層からなる MLP 層を設ける。MLP 層は以下の関数で定義される。

$$f_{MLP}(x) = \mathbf{W}_M^T (\dots ReLU(\mathbf{W}_2^T x + \mathbf{b}_2) \dots) + \mathbf{b}_M \quad (17)$$

ここで、各ユーザ表現および POI 表現はそれぞれの MLP 層にもとづいて以下のように変換される。

$$u'_o = f_{MLP,OTU}(u_o), u'_h = f_{MLP,HTU}(u_h) \quad (18)$$

$$v'_o = f_{MLP,OTP}(v_o), v'_h = f_{MLP,HTP}(v_h) \quad (19)$$

次に、出力層により、ユーザと POI のスコアを獲得する。Out-Of-Town 特有の嗜好を捉えたスコア s_o および地理的位置関係を考慮し日常的な嗜好を捉えたスコア s_h は、それぞれ以下の式で算出される。

$$s_o = \mathbf{W}_o^T (u'_o \odot v'_o) + b_o \quad (20)$$

$$s_h = \mathbf{W}_h^T (u'_h \odot v'_h) + b_h \quad (21)$$

4.3.2 スコアの使い分け

提案手法 OTP-KGAT では、算出した 2 つのスコア s_o および s_h を、ユーザの Home-Town と訪問先地域の組み合わせに応じて使い分けることで、地域間の地理的距離を考慮した Out-Of-Town 傾向の変化に対応する。直感的には、地域同士が地理的に遠く離れているほど s_o を重視し、隣接する地域で

あれば日常的な嗜好をもとに地理的行動範囲を考慮した s_h を比較的高めに考慮するような設計を行う。しかし、POI 推薦における地理的バイアスは、直線的なエリア間の距離に依存せず、影響を及ぼしあうことがある。例えば、東京と大阪間を移動するユーザは仕事で出張として移動しているケースが比較的多く、このようなユーザは訪問先においても、日常と変わらない訪問を行う可能性がある。このような非線形な地理的距離関係を考慮するため、直接的な地理的距離をもとにスコアの比率を決定するのではなく、協調知識グラフの学習を通して獲得した地域表現を用いてスコアの比率を以下の式で決定する。

$$\alpha = \text{Sigmoid}(\mathbf{W}_\alpha^T (\mathbf{r}_{h,Home} \odot \mathbf{r}_{h,POI}) + b_\alpha) \quad (22)$$

ここで、 $\mathbf{r}_{h,Home}$ は HT 協調知識グラフをもとに獲得したユーザの居住地の地域表現、 $\mathbf{r}_{h,POI}$ は POI が属する地域の地域表現である。この比率を用いて、最終的な予測スコアは以下の式で算出される。

$$s = (1 - \alpha)s_o + \alpha s_h \quad (23)$$

4.3.3 損失関数

本論文では、学習期間において訪問行動が起こったユーザ - POI のペアを 1、起こらなかった一部のサンプルに 0 の真値スコアを割り当てた Binary Cross Entropy (BCE) 損失を最小化することでモデルを学習する。BCE 損失は以下の関数で定義される。

$$f_{BCE}(y, \hat{y}) = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})) \quad (24)$$

y および \hat{y} はそれぞれ、真値スコアおよび予測スコアである。

提案手法 OTP-KGAT は、全体で 3 つのスコアを算出するが、 s だけを BCE 損失により最適化した場合、学習初期段階で精度が高いどちらか一方のみのスコアの精度を高めれば全体の精度が高くなると判断され、もう一方のスコアの学習が促進されない可能性がある。そこで提案手法では、長期的に双方のスコアの精度を高めたうえで、有効な比率で 2 つのスコアを使い分けることを目的として、モデルが算出する 3 つのスコアそれぞれについて損失項を設ける。協調フィルタリングのための損失関数は以下のように定義する。

$$\begin{aligned} \mathcal{L}_{BCE} = & \frac{1}{|\mathcal{O}_{OT}|} \sum_{(u,i,y) \in \mathcal{O}_{OT}} (f_{BCE}(y, \sigma(s_{ui})) + f_{BCE}(y, \sigma(s_{o,ui}))) \\ & + \frac{1}{|\mathcal{O}_{OT}| + |\mathcal{O}_{HT}|} \sum_{(u,i,y) \in \mathcal{O}_{HT}, \mathcal{O}_{OT}} f_{BCE}(y, \sigma(s_{h,ui})) \end{aligned} \quad (25)$$

ここで、 $\sigma()$ は Sigmoid 関数である。また、 \mathcal{O}_{OT} はユーザの Out-Of-Town 訪問履歴から作成した学習データセット、 \mathcal{O}_{HT} はユーザの Home-Town 訪問履歴から作成した学習データセットであり、各要素はユーザ u 、POI i 、 u と i の真値スコア y からなるトリプレットである。このような損失関数を最適化することで、 s_o と s_h のスコア双方を最適化しつつ、 s に用いる最適な比率を決定することが可能となる。また、 s_o は \mathcal{O}_{OT} のみに由来して最適化を行うため、ユーザの Out-Of-Town 訪問履

歴のみを考慮したスコアとして学習され、 s_h は比較的データが多い \mathcal{O}_{HT} を中心に \mathcal{O}_{OT} までに考慮して最適化を行うため、ユーザの日常的な訪問や地理的距離による訪問の起こりにくさも考慮したスコアとして学習される。

4.3.4 学習データセットの割り当て

提案手法では、 s_o と s_h それぞれの目的が顕著に反映されるような負例の割り当て方法を提案する。提案手法では、協調グラフにおけるユーザノードの表現は直接的には推薦に用いないため、POI 表現をうまく学習できた方が精度の向上に繋がると考えられる。そこで、POI ベースで各 POI に均等に負例を割り当てる方法を採用する。それぞれの学習データセットは以下の手順で割り当てられる。

\mathcal{O}_{OT} の割り当て

- 1: ユーザの Out-Of-Town 訪問を正例として割り当て
- 2: POI あたりの Out-Of-Town 訪問の平均数 N_{OT} を計算
- 3: すべての POI について、属する地域 r_{POI} に Out-Of-Town として訪問かつその POI に未訪問のユーザから N_{OT} 人を負例として割り当て

ランダムに負例を割り当てるのではなく、手順 3 の条件を設けることで、地理的距離による影響を最小限にし、ユーザの POI の内容に対する嗜好のネガティブさを考慮したサンプリングが可能となる。

\mathcal{O}_{HT} の割り当て

- 1: ユーザの Home-Town 訪問を正例として割り当て
- 2: POI あたりの Home-Town 訪問の平均数 N_{HT} を計算
- 3: すべての POI について、属する地域 r_{POI} に Home-Town として訪問かつその POI に未訪問のユーザから N_{HT} 人を負例 1 として割り当て
- 4: すべての POI について、属する地域 r_{POI} に未訪問のユーザから N_{HT} 人を負例 2 として割り当て

\mathcal{O}_{HT} の割り当てでは、新たに手順 4 を設ける。これは、 s_h を地理的距離による訪問の起こりにくさを考慮したスコアとして学習するため、遠いからその POI に来ないというユーザを考慮するためである。

4.4 転 移 層

提案手法 OTP-KGAT では、ユーザが未訪問の地域に対して Home-Town の訪問シーケンスのみで推薦が可能となるように、 \mathbf{u}_h から \mathbf{u}_o を再現する転移層を推薦モデルと同時に学習する。ユーザの Home-Town から Out-Of-Town にかけての訪問傾向ドリフトは、大きく 2 つに大別して捉えることができる。1 つ目はカテゴリ的嗜好ドリフトである。ユーザは Out-Of-Town において、観光的な特性を有す POI に好んで訪問する傾向や普段よりも少しサービスの価格帯が高い POI に訪問する傾向がある。2 つ目は、地域依存の嗜好ドリフトである。例えば、神社仏閣の多い京都府のような地域と商業施設が多い大阪のような地域とでは、同じ寺であっても都市内における重要度合い

表 1 データセットの詳細

	ユーザ	POI	地域	カテゴリ	OT 訪問	HT 訪問
総数	24,176	10,539	8	26	385,849	621,808

表 2 OT 訪問する地域間のユーザ数（縦軸：居住地、横軸：訪問先）

	東京	埼玉	神奈川	千葉	大阪	京都	兵庫	奈良
東京		4,770	4,842	2,721	137	98	40	36
埼玉	3,006		746	709	23	15	11	5
神奈川	4,298	907		600	41	37	17	16
千葉	1,590	665	452		15	11	4	1
大阪	97	41	70	30		1,762	2,288	981
京都	47	8	28	6	811		246	272
兵庫	13	6	11	2	1,552	285		136
奈良	10	3	7	2	469	231	77	

が変化する。これら 2 つのドリフトを捉えるため、提案手法ではユーザの Home-Town と訪問先地域に依存した転移層を提案する。転移層を以下の式で定義する。

$$\mathbf{v}_{transH} = \mathbf{W}_{transH}^T \mathbf{r}_{h,Home} + \mathbf{b}_{transH} \quad (26)$$

$$\mathbf{v}_{transO} = \mathbf{W}_{transO}^T \mathbf{r}_{o,POI} + \mathbf{b}_{transO} \quad (27)$$

$$\mathbf{u}_o^* = \mathbf{v}_{transO} \odot \mathbf{v}_{transH} \odot \mathbf{u}_h \quad (28)$$

次に、 \mathbf{u}_o^* が \mathbf{u}_o を再現するように転移層を学習するため、以下の損失関数が小さくなるように最適化を行う。

$$\mathcal{L}_{TRA} = \frac{1}{|\mathcal{O}_{OT}|} \sum_{(u,i,y) \in \mathcal{O}_{OT}} \|\mathbf{u}_{o,u} - \mathbf{u}_{o,u}^*\|^2 \quad (29)$$

テスト時には、 \mathbf{u}_o の代わりに \mathbf{u}_o^* を用いることで、ユーザが未訪問の地域内の POI に対して Home-Town の訪問シーケンスのみでスコアリングが可能となる。

4.5 学 習

学習は KGAT の学習フレームワークにならって、以下の手順を繰り返す行う。

- (1) $\mathcal{L}_{BCE} + \mathcal{L}_{TRA} + \lambda \|\Theta\|_2^2$ を最適化
- (2) $\mathcal{L}_{KG,OT} + \lambda \|\Theta_{OT}\|_2^2$ を最適化
- (3) $\mathcal{L}_{KG,HT} + \lambda \|\Theta_{HT}\|_2^2$ を最適化

ここで、 Θ はモデルのパラメータ全体、 Θ_{OT} および Θ_{HT} はそれぞれ、 Θ のうち OT 協調グラフに関するパラメータおよび Θ のうち HT 協調グラフに関するパラメータである。

5 評価実験

実データを用いた実験により、提案手法における Out-Of-Town POI 推薦の有効性を検証した。

5.1 評価環境

5.1.1 データセット

本実験では、Wi-Fi サービスプロバイダによって設置された Wi-Fi アクセスポイントにより収集された、データ活用に関する許諾を個別に得ている利用者を対象としたアクセス記録を使用した。アクセス記録は、ユーザがアクセスを行った時間、

表 3 タスク設定 A ($u \in \mathcal{U}$) における精度

	東京		埼玉		神奈川		千葉		大阪		京都		兵庫		奈良	
<i>Recall</i>	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100
TopPopular	0.137	0.304	0.087	0.355	0.085	0.283	0.089	0.385	0.133	0.322	0.133	0.595	0.054	0.387	0.197	0.779
BPRMF	0.113	0.297	0.091	0.332	0.102	0.312	0.072	0.367	0.048	0.127	0.116	0.455	0.046	0.371	0.221	0.730
KGAT	0.047	0.195	0.117	0.271	0.049	0.216	0.076	0.299	0.029	0.206	0.062	0.425	0.032	0.250	0.129	0.746
CAPTOR	0.111	0.235	0.071	0.284	0.088	0.302	0.058	0.361	0.111	0.316	0.065	0.535	0.043	0.374	0.186	0.741
OTP-KGAT	0.166	0.380	0.135	0.457	0.126	0.406	0.108	0.410	0.154	0.329	0.125	0.567	0.070	0.464	0.272	0.751
精度向上率	21.2%	24.6%	15.4%	28.7%	23.5%	30.1%	4.9%	6.5%	10.8%	2.2%	-	-	29.6%	20.0%	23.0%	-

表 4 タスク設定 B ($u^* \notin \mathcal{U}$) における精度

	東京		埼玉		神奈川		千葉		大阪		京都		兵庫		奈良	
<i>Recall</i>	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100	@10	@100
TopPopular	0.086	0.282	0.083	0.319	0.085	0.305	0.095	0.334	0.133	0.330	0.132	0.550	0.073	0.378	0.152	0.717
CAPTOR	0.044	0.235	0.059	0.263	0.067	0.255	0.061	0.300	0.076	0.290	0.076	0.455	0.071	0.345	0.118	0.685
OTP-KGAT	0.144	0.425	0.145	0.499	0.115	0.419	0.112	0.412	0.152	0.391	0.130	0.543	0.076	0.454	0.184	0.724
精度向上率	69.4%	50.7%	74.7%	56.4%	35.3%	37.4%	17.9%	23.4%	14.3%	18.5%	-	-	4.1%	20.1%	21.1%	1.0%

ユーザの ID, 店舗名, 店舗の所在地, カテゴリ等が記録されている。今回は対象の地域として、関東圏と関西圏の計 8 地域を用いた。データセットの統計情報を表 1, 2 に示す。学習に用いるユーザは比較的訪問数が多い、OT 訪問, HT 訪問それぞれを 10 件以上もつものに限定している。OT 訪問が 10 件以上のユーザは全体の極めて一部であるが、一部のデータが多いユーザで学習すれば OT 訪問が少ないユーザにも適応可能である。また、学習に用いる POI は、OT 訪問, HT 訪問それぞれを 5 件以上もつものに限定している。

5.1.2 評価方法

タスクは 3 章のタスク定義に従う。正解データは指定地域におけるユーザのすべての訪問行動となっており、1 ユーザに対して複数存在する。評価指標には Recall@k を用いる。テストユーザは、地域を選択した際に条件を満たすユーザについて一部をサンプリングして用いる。

5.1.3 比較手法

提案手法の有効性を示すため、既存手法を 3 節で定義するタスク設定下に適応する形で評価を行った。比較した手法は以下の通りである。

機械学習を用いない手法

- **Top Popular**: 対象地域内の POI について学習期間内に Out-Of-Town として訪問したユーザの訪問件数の多い順に推薦結果とした手法

一般的な推薦手法

- **BPRMF** [4]: ペアワイズランキング損失を用いて MF を学習する手法
- **KGAT** [7]: 提案手法のベースとなった協調知識グラフベースの推薦手法

Out-Of-Town POI 推薦手法

- **CAPTOR** [4]: ユーザの Out-Of-Town 訪問は Home-Town 近隣の地域で起こりやすいという仮定のもと、訪問先が未知なタスク設定を想定した Out-Of-Town POI 推薦手法

5.2 実験結果

5.2.1 タスク設定 A による既存手法との比較 (Q1)

モデルの学習に登場するユーザ $u \in \mathcal{U}$ について既存手法と比較した結果を表 3 に示す。テスト期間としては、学習期間の次の 2 週間を用いたため、テストに用いるユーザは連続して異なる地域に Out-Of-Town 訪問する比較的アクティブなユーザであり、運送や営業などに従事している特異的なユーザである可能性が高い。したがって、このタスク設定が可能なユーザは全体の一部である。

提案手法は、推薦精度は京都と奈良を除き、ほぼすべての地域で比較手法を大きく上回る精度を達成している。提案手法の次に高い精度を達成している手法は概ね Top Popular である。一般的な Home-Town 周辺の訪問傾向からユーザの嗜好を捉え、暗示的に Home-Town 周辺の POI についてスコアが高くなるように学習された一般的な手法は、地理距離が離れた地域内の POI について効果的なスコアリングを行えていない。また、CAPTOR は Out-Of-Town POI 推薦特化の手法であるが、遠方地域の POI について適切なスコアリングを行えない。そのため、一般的な手法と同等の精度となっている。

一方、Top Popular は強力なベースラインとなっている。これは、Out-Of-Town 訪問では観光地など大衆的な人気度が高く、地域を象徴する POI に訪問が集中する性質があるためと考えられる。特に神社・仏閣などを多く有し観光の特性が強い京都では、Top Popular が OTP-KGAT を上回る精度を達成している。このような観光的な特性が強い地域に関しても、Top Popular を上回る精度を達成することが今後の課題である。

5.2.2 タスク設定 B による既存手法との比較 (Q2)

モデルの学習に登場しないユーザ $u^* \notin \mathcal{U}$ について既存手法と比較した結果を表 4 に示す。タスク B は、学習したユーザ表現をテストに用いる一般的な推薦手法とは、比較不可能である。ユーザの Out-Of-Town 訪問は、非日常的で非常に稀なケースであるため、多数のユーザがこの設定に該当する。また、

表 5 スコア比率 α (縦軸: 居住地, 横軸: 訪問先)

	東京	埼玉	神奈川	千葉	大阪	京都	兵庫	奈良
東京	-	0.272	0.224	0.235	0.198	0.212	0.208	0.235
大阪	0.198	0.188	0.166	0.181	-	0.235	0.177	0.234




図 3 東京 (右), 大阪 (左) に関するスコア別の精度推移

Home-Town 内訪問シーケンスは比較的密であり, 多くのユーザがタスク B の推薦に十分な Home-Town 内訪問シーケンスを有している。

提案手法はこのタスク設定においても, タスク A と同等な精度を達成している。これは, Attention 機構により効果的にユーザのパーソナライズな表現を作成するアプローチと, 近似的に Home-Town のユーザ表現から Out-Of-Town のユーザ表現を再現する転移層が効果的に働いているためである。

5.2.3 スコア比率 α の分析 (Q3)

居住地が東京と大阪の場合のスコア比率 α を表 5 に示す。 α の値が大きいくほど HT スコアを重視するようになる。結果から, 全体的に OT スコアの方を重視したスコアリングとなるように学習されていることが分かる。これは, 近隣の Out-Of-Town においても, ユーザは訪問傾向が変化する可能性が高く, OT スコアの方が全体的に妥当であることを示している。

都道府県ごとの結果では, 東京では埼玉, 大阪では京都の α の値が最も高く, 近隣の都道府県では高くなる傾向がある。これは, 近い地域では訪問の Out-Of-Town 傾向度合いが低く, HT スコアの影響が大きいユーザが多いためである。しかし, 東京-奈良間や大阪-兵庫間などこれに従わない地域ペアも存在する。この原因として, 二つの要因が考えられる。一つ目は地域ペアのデータが少ない点である。例えば, 東京-奈良間は表 2 に示す通り, 学習データとなるユーザが 10 人しか存在しない。学習データが十分に確保できた場合, 結果が変わる可能性がある。二つ目は, 訪問の Out-Of-Town 傾向の度合いは地域間レベルではなく, ユーザレベルで変化する可能性がある点である。今回のアプローチでは, 県境付近に住むユーザにも県境から最も遠い場所に住むユーザにも, Home-Town が同じユーザであれば様な比率が割り当てられるが, これらのユーザでは訪問傾向の変化の度合いが異なることは明らかである。今後は, ユーザごとに α を決定する手法について検討する必要がある。

提案手法における, HT スコアと OT スコアを使い分けるアプローチは精度に大きく貢献している。東京と大阪における各スコアを用いた際の精度推移を図 3 に示す。それぞれのスコアで異なる精度の推移となっており, 双方が異なる観点でスコアリングを行っていることが分かる。東京では, OT スコアに比

べて, HT スコアの精度が高い。これは, 東京が大阪に比べて通勤通学など近隣地域間の結びつきが強いためであると考えられる。一方, 関西は関東圏と比較して, 生活圏が都道府県ごとに分かれていることが影響して, HT スコアよりも OT スコアの精度が高くなっていると考えられる。地域によって各スコアの影響の度合いは異なるものの, いずれの地域においても双方を考慮した場合が最も高い精度となっている。そのため, 2つのスコアを使い分けるアプローチが有効であるといえる。

6 結 論

本論文では, 複数地域を同時学習により, 未訪問の指定地域内でパーソナライズな Out-Of-Town POI 推薦を行うタスク設定を想定した提案手法 OTP-KGAT を提案した。本論文はこのようなタスク設定を行った初めての研究である。この設定は訪問先地域は決まった上で, 訪問先 POI の情報を収集するユーザのユースケースに最も合致したタスク設定である。OTP-KGAT は実世界のサービス上で収集されたデータセットにおいて, 既存手法を上回る推薦精度を達成し, 手法の有効性を示した。今後は2つのスコアをユーザレベルで使い分けることによる提案手法の改善を検討する。

謝 辞

本研究はの一部は, JST CREST (JPMJCR21F2) の助成によるものである。

文 献

- [1] Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K.: Bert: Pre-training of deep bidirectional transformers for language understanding, *arXiv preprint arXiv:1810.04805* (2018).
- [2] Ding, J., Yu, G., Li, Y., Jin, D. and Gao, H.: Learning from Hometown and current city: Cross-city POI recommendation via interest drift and transfer learning, *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, Vol. 3, No. 4, pp. 1–28 (2019).
- [3] Lin, Y., Liu, Z., Sun, M., Liu, Y. and Zhu, X.: Learning entity and relation embeddings for knowledge graph completion, *Proc.AAAI* (2015).
- [4] Rendle, S., Freudenthaler, C., Gantner, Z. and Schmidt-Thieme, L.: BPR: Bayesian personalized ranking from implicit feedback, *arXiv preprint arXiv:1205.2618* (2012).
- [5] Rendle, S., Gantner, Z., Freudenthaler, C. and Schmidt-Thieme, L.: Fast context-aware recommendations with factorization machines, *Proc.SIGIR*, pp. 635–644 (2011).
- [6] Sun, H., Xu, J., Zhou, R., Chen, W., Zhao, L. and Liu, C.: HOPE: a hybrid deep neural model for out-of-town next POI recommendation, *World Wide Web*, Vol. 24, No. 5, pp. 1749–1768 (2021).
- [7] Wang, X., He, X., Cao, Y., Liu, M. and Chua, T.-S.: Kgat: Knowledge graph attention network for recommendation, *Proc.SIGKDD*, pp. 950–958 (2019).
- [8] Xin, H., Lu, X., Xu, T., Liu, H., Gu, J., Dou, D. and Xiong, H.: Out-of-Town Recommendation with Travel Intention Modeling, *Proc.AAAI*, pp. 4529–4536 (2021).
- [9] Xin, H., Lu, X., Zhu, N., Xu, T., Dou, D. and Xiong, H.: CAPTOR: A Crowd-Aware Pre-Travel Recommender System for Out-of-Town Users, *Proc.SIGIR*, pp. 1174–1184 (2022).