

LUVT 非破壊探傷のためのデータ拡張

中島 未椰[†] 斎藤 隆泰[†] 加藤 毅^{††}

[†] 群馬大学大学院理工学府 〒 376-8515 群馬県桐生市天神町 1-5-1

^{††} 群馬大学情報学部 〒 371-8510 群馬県前橋市荒牧町 4-2

あらまし 近年、超音波非破壊検査において、非接触で効率よく検査を実施できることから、レーザー超音波可視化試験 (LUVT) が注目されている。LUVT で得られた画像から深層学習で欠陥検出する試みがなされている一方、LUVT 画像の収集には多くの費用と時間を要するため、大規模なデータセットを用意することは困難である。このような教師データの不足を補うため、本研究では、シミュレーション LUVT 画像にスタイル変換を適用したデータ拡張手法を提案する。数値実験により、提案手法が欠陥の分類性能を向上させたことを報告する。

キーワード 深層学習、データ拡張、スタイル変換、LUVT

1 緒 言

近年、構造物の老朽化などの社会的背景から、構造物の維持管理を目的とした非破壊検査の需要が高まっている。特に超音波非破壊検査は、検査効率や安全性の観点で優れており、幅広く用いられてきた。本論文では、超音波非破壊検査の中でも、レーザー超音波を用いたレーザー超音波可視化試験 (LUVT) に注目する(図 1)。LUVT では、超音波が伝搬する様子を画像化することができ、LUVT により得られた画像から、欠陥の有無を判定することができる。

しかし、現状の超音波非破壊検査では、検査員が目視で欠陥の有無を精査する必要がある。増加の一途を辿る非破壊検査の需要に対して、技術者の不足や負担の増加が非破壊検査の現場を悩ませている。解決策として、近年、超音波非破壊検査に機械学習の技術を導入し、検査の省力化を図る試みが検討され始めた[8], [10], [20]。

本研究の目標は、深層学習モデルを使って LUVT で得られる画像を自動検査する技術の開発である。しかし、一般的な画像認識タスクと比較すると、非破壊検査のための訓練用画像の収集には、多くの費用と時間を要するため、利用可能なデータ数は制限される。したがって、大量の訓練データに依る深層学習モデルの汎化性能は、データの不足が原因となり、減退せられる。

そこで本論文では、LUVT 画像検査における、シミュレーション画像を活用した効果的なデータ拡張手法を提案する。シミュレータは、LUVT の測定にかかるコストをかけずに、多様な試験体内部の欠陥の画像を生成することができる。しかし、シミュレーション画像と実画像との間に差異が存在し、直接、訓練データに追加することで、学習に悪影響が生じるため、欠陥検出に有用なモデルの構築は難しくなる。これに対して、スタイル変換技術を施すことにより、シミュレーション画像を実画像に近づけることを考案した。本論文では、その具体的な方法論を示し、その効果を実証する実験結果を報告する。

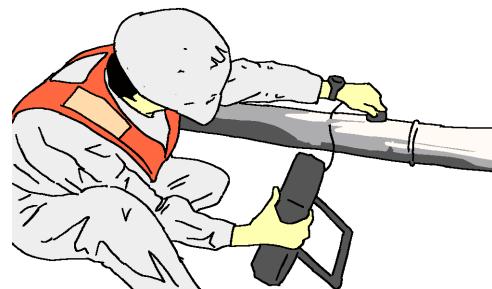


図 1: 超音波非破壊検査の作業風景。



図 2: 試験体の制作工程。

2 関連研究

2.1 データ拡張

データ拡張とは、データを擬似的に水増しし、データセットの大規模化を図る手法である。近年の深層学習において、画像認識における汎化性能はデータセットの大きさに強く依存するため、データ拡張は必要不可欠である。データ拡張は、個々の画像認識タスクに応じて、経験に基づいた適用が容易であり、汎用的なモデルの構築が可能となる。

2.2 既存画像の単純変換によるデータ拡張

一般画像認識で、单一画像に施される代表的なデータ拡張として、画像の反転、回転、切り抜きなどの幾何的な変換と色相、明度の変換などが挙げられる。これらの代表的なデータ拡張について、図 3 に例示する。それ以外にも、画像を部分的にマ

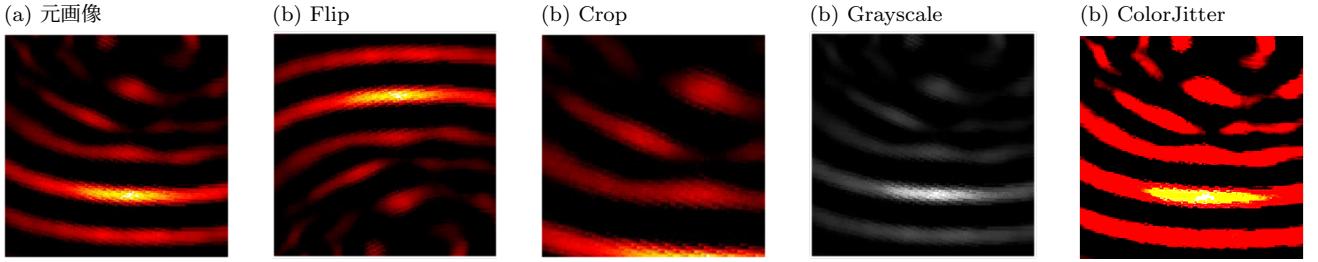


図 3: 単純変換によるデータ拡張.

スクする Cutout [3] もよく用いられる. Karen ら [12] は、画像の回転、切り取り等を用いて、ImageNet データセットで性能が向上することを実証した.

そのほかのアプローチに複数の画像から合成して新しい画像を生成する方法がある. Mixup [18] は 2 つの画像の線形結合をとり、ラベルについても同様に合成する. また、Mixup と Cutout を合わせることで改良した CutMix [17] も注目されている. Wang ら [15] は、YOLOv4 で CutMix をデータ拡張として用いることで、物体検出性能での効果を検証した.

また、Generative Adversarial Networks (GAN) [5] を用いたデータ拡張も提案されている. GAN は生成モデルの一種であり、敵対的学習を介して、高品質な画像を生成する. GAN を用いたデータ拡張の研究は、主に医療の分野で進められており、IAGAN [9] や PGGAN [2] を用いたデータ拡張が成功している.

しかし、既存画像の変換によるデータ拡張は、しばしば未知データでは存在しないような画像を作り出してしまう. このような、学習に対して効果的でないデータ拡張については、モデルの汎化性能を低下させる大きな要因となる.

2.3 シミュレータによるデータ拡張

シミュレータによるデータ拡張は、既存画像の単純変換と比べていくつかの利点をもつ. 一つ目の利点は、目的に即した画像を生成できる点である. シミュレータは、利用者が設定した特定の条件を満たすように、多様な画像を生成できる. 二つ目の利点は、生成された画像を大規模に利用可能な点である. シミュレータを使う場合、画像取得のコストをかけずに十分な画像枚数を獲得できる.

シミュレータによるデータ拡張は、ロボットビジョン [13]、自動運転 [7]、医療画像 [1] においてその効果が報告されている. しかし、LUVT 画像の判別においては、シミュレータが生成した画像は、実際に測定された画像との差異が大きい. このような画像の性質から、直接的な利用はかえって予測性能の低下を招く.

3 LUVT とデータセット

3.1 LUVT とは

LUVT を用いた非破壊検査では、図 4 に示すように、まず試験体にレーザーを照射し、レーザー照射点（送信点）において超音波を発生させる. そして、予め設置した超音波探触子から、超音波を送信しているような画像を得ることができる. この操作をアルミ試験体に対して適用し、得られた画像を図 5 に示す. 欠陥がない画像に関しては、上に設置された探触子からの入射超音波は、そのまま伝搬する. その一方、欠陥が存在する画像の場合には、入射された超音波とは別に、欠陥から発生した散乱波が等方的に広がる. これにより、熟練の技術者でなくとも、図 5 のように欠陥からの散乱波が発見できる.

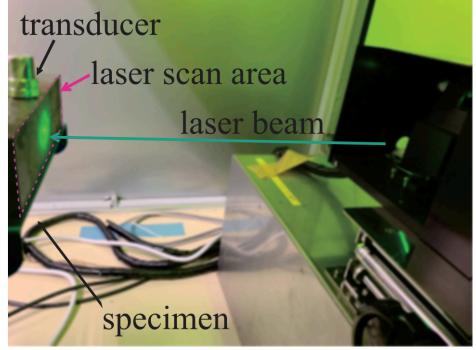


図 4: LUVT 装置. 右の装置から試験体表面にレーザを照射することで、その照射面での超音波伝搬を画像化できる.

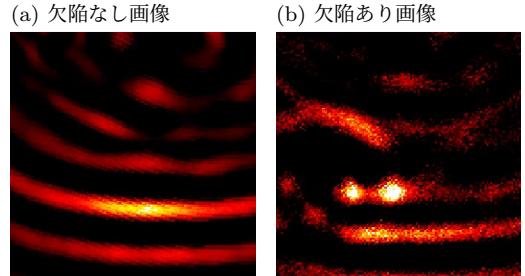


図 5: LUVT 実画像の例. (a) は欠陥なし画像を表しており、上方から入射された超音波は、そのまま伝搬する. (b) は欠陥あり画像を表しており、上方から入射された超音波とは別に、欠陥から発生した散乱波を確認できる.

て超音波を発生させる. そして、予め設置した超音波探触子から、超音波を送信しているような画像を得ることができる. この操作をアルミ試験体に対して適用し、得られた画像を図 5 に示す. 欠陥がない画像に関しては、上に設置された探触子からの入射超音波は、そのまま伝搬する. その一方、欠陥が存在する画像の場合には、入射された超音波とは別に、欠陥から発生した散乱波が等方的に広がる. これにより、熟練の技術者でなくとも、図 5 のように欠陥からの散乱波が発見できる.

3.2 大規模データセット取得の難しさ

LUVT で得られる画像は、測定ノイズが原因で、人間でも欠陥からの散乱波を視認できない場合がある. このような画像を

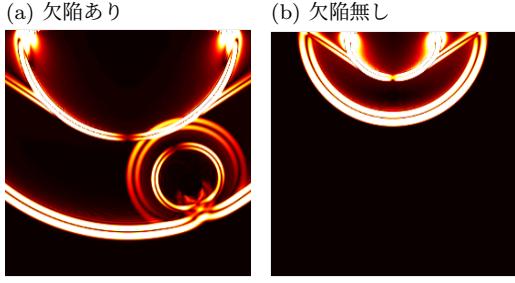


図 6: シミュレーション LUVT 画像の例. (a) は欠陥なし画像, (b) は欠陥あり画像を表している. 実 LUVT 画像と比較すると, 画像スタイルに差異が生じている.

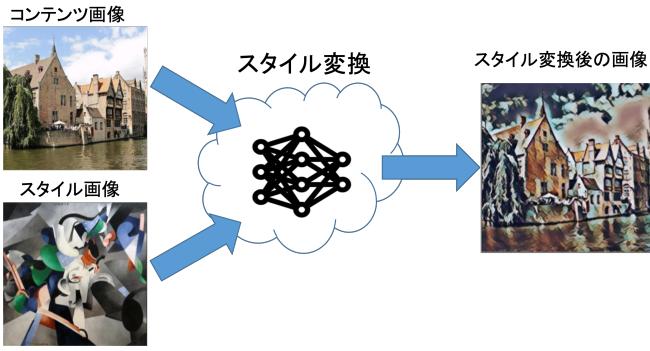


図 7: スタイル変換の例.

高精度で判別するには, 大量の訓練画像が必要になる. LUVT 画像の正例を得るには次の工程を要する.

- (1) 試験体を用意する. 後述する実験ではアルミ板を用いた.
- (2) ドリルなどを使って試験体の内部に人工的に欠陥を作る(図 2).
- (3) 前節に述べたイメージングの方法で, LUVT 画像を得る.

以上を繰り返して正例を得る. 負例を得るには, ステップ 1 とステップ 3 のみ実施する. ただし, 実際に想定する試験体は, 高価な場合も多く, データセットを構成するのに必要な数だけ, 費用がかかる. また, 装置を用いての測定と画像化を繰り返し行うため, 時間と労力を要する. これが障壁となり, LUVT データセットの大規模化は妨げられている.

4 提案手法

4.1 シミュレータによる画像生成

LUVT 画像に相当する超音波伝搬画像をシミュレーションで求めるには, 試験体に対する境界条件と初期条件の下, 超音波が満足する弾性波動方程式を解く必要がある. 弾性波動方程式を解くために用いられる方法として, 差分法や有限要素法[21], 境界要素法[22]が知られている. 境界要素法は, 高精度な波動解析手法として知られているが, その分, 比較的多くの計算時間を要する. 一方, 差分法や有限要素法は, 比較的少ない計算時間で, 数値解を求めることができる.

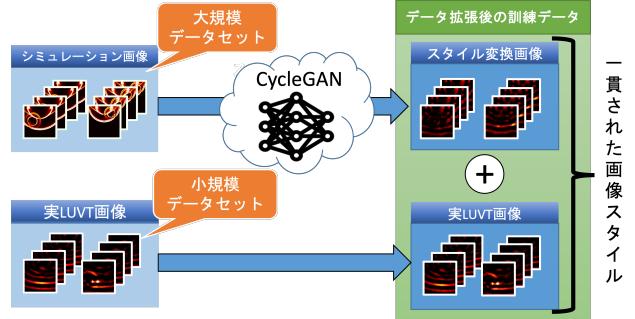


図 8: 提案法の概略. シミュレーション画像を直接用いず, CycleGAN を介し, データ拡張を行う.

本研究では, LUVT 画像に相当する大量の人工画像を用意するため, 短時間で荒い数値解を求めることができる時間領域差分法を用いてシミュレーション画像を得た. 得られたシミュレーション画像は, 図 6 に示す.

4.2 スタイル変換

実際に獲得した LUVT 画像は, シミュレータで生成した画像との間に差異がある. LUVT 画像獲得の過程で, 様々な要因でノイズが混入する. しかし, LUVT のシミュレータは物理現象の理解を目的としているため, 超音波の散乱から画像構成に至るまでの過程を完全に再現するには至らない. この差分がドメインシフトを引き起こし, シミュレータでの水増し画像では, 汚化性能の向上につながらない. そこで, シミュレータで生成した画像を, 直接訓練画像として加えるのではなく, 実画像に近づけるための変換を行う.

本研究では, シミュレータで生成した画像を実画像に近づけるための手段として, 画像認識分野で開発されたスタイル変換と呼ばれる技術を応用する. スタイル変換は, 形や物体の配置などの特徴を持ったコンテンツ画像と, 色やテクスチャーの情報を有するスタイル画像を入力として, 新しい画像を生成する(図 7). 本論文では, LUVT の自動判別のための訓練データ拡張に, 教師なし学習に基づくスタイル変換器[19]の導入を提案する. 教師なし学習に基づくスタイル変換器では, コンテンツ画像群からコンテンツドメインの学習を行い, 同時にスタイル画像群スタイルドメインの学習を行う. Zhu ら[19]が CycleGAN と呼ばれるスタイル変換器を開発し, この 2 つのドメインの学習によって, 実際の絵画から風景写真といった画風変換が可能なことを実証した. 後述の実験では, CycleGAN を使って, LUVT 画像の判別における, データ拡張の効果を検証した.

また, 教師あり学習に基づくスタイル変換器の可能性に関しても議論する価値がある. 教師ありスタイル変換は, 入力画像とそのスタイルを変換した出力画像のペアとして事前に用意し, この情報に基づいて対応関係を学習させる. Isola ら[6]は教師ありスタイル変換器として Pix2Pix を開発し, グレースケール画像をカラー画像に変換するなどを実証した. しかし, LUVT への応用においては, 入力画像とそのスタイルを変換した出力画像のペアを事前に用意するのは困難である. 本研究では, 教

表 1: CycleGAN によるスタイル変換. スタイル変換器が学習を重ね, 20000 反復に到達すると, シミュレーション画像が右のような実 LUVT 画像のスタイルに近づいていることがわかる.

ラベル	0 iterations	100 iterations	10,000 iterations	20,000 iterations	実 LUVT 画像
欠陥なし					
欠陥あり					

師ありスタイル変換器は採用しなかった.

4.3 スタイル変換によるデータ拡張

提案法の概略を図 8 に示す. まず, 実画像群の獲得と同時に, シミュレータを使ってシミュレーション画像群を得る. 次に, 実画像の集合およびシミュレーション画像群を使って, CycleGAN を学習し, それぞれのシミュレーション画像をスタイル変換する. 実画像とスタイル変換したシミュレーション画像を合わせて訓練用画像とし, 欠陥検出のための深層学習モデルを学習する. 以降で述べる比較実験では, 提案手法の有用性を確かめるべく, LUVT データセットを用いて検証を行う.

5 実 験

本節では, 以下のように実験結果を報告する. まず初めに, シミュレーション LUVT 画像のスタイル変換の結果を視覚的に確認し, 実際に実画像のスタイルに近づいているか検証する. 次に, この結果を踏まえ, スタイル変換を施した画像を用いて, データ拡張を行なう有効性を示す.

5.1 シミュレーション LUVT 画像のスタイル変換実験

5.1.1 実験条件

シミュレーション画像を実画像に近づけるために, CycleGAN を用いて, スタイル変換を行なった. 本実験では, コンテンツ画像にシミュレーション画像, スタイル画像に実 LUVT 画像を用いた. シミュレーション LUVT データセットは, 55 箇所の欠陥位置ごとの画像集合から構成され, 1 つの画像集合は 431 枚である. 実 LUVT データセットは, 203 箇所の欠陥位置ごとの画像集合から構成され, 1 つの画像集合は 134 枚である. CycleGAN の学習に用いた最適化アルゴリズムは Adam であり, 学習率を 0.0002 に設定した. そして, CycleGAN の学習を 20,000 反復繰り返すことで, スタイル変換後の画像を獲得した.

5.1.2 スタイル変換結果の観察

CycleGAN を用いて, シミュレーション画像をスタイル変換し, 得られた画像を表 1 に示す. 左から CycleGAN の学習の過程において, 0, 100, 10,000, 20,000 反復のモデルに対し, シ

表 2: モデルの学習に用いたパラメータ

	EfficientNet	ResNeXt	ViT
入力サイズ	(3, 224, 224)	(3, 224, 224)	(3, 224, 224)
エポック	30	30	30
バッチサイズ	128	128	256
最適化アルゴリズム	Adam	Adam	AdamW
学習率	0.01	0.01	0.0001

表 3: 画像分類に用いたデータセット

	欠陥なし画像数	欠陥あり画像数
実画像	22,634	4,567
シミュレーション画像	17,111	6,594
スタイル変換画像	17,111	6,594

ミュレーション LUVT 画像をスタイル変換した画像の一例である. それぞれの画像で, 波の色, 欠陥の視認性などの点で, 違いが見られたが, CycleGAN で学習を重ねることで, LUVT 画像のスタイルに近づいていることが確認できる. 以降の実験では, スタイル変換画像でデータ拡張することで, 深層学習モデルの欠陥検出性能が向上することを実証する.

5.2 LUVT 画像の欠陥検出

5.2.1 実験条件

スタイル変換によるデータ拡張の有用性を確かめるため, 実験では, LUVT 画像のみの場合, シミュレーション LUVT 画像でデータ拡張した場合, スタイル変換画像でデータ拡張を行なった場合についての比較を行なった.

以上の手法において, EfficientNet [14], ResNeXt [16], Vision Transformer (ViT) [4] を用いて, その性能を検証した. それぞれのモデルで, 学習に使用したパラメータは表 2 に示す. 学習中のデータ拡張には, HorizontalFlip のみを用い, ImageNet で事前学習された重みを初期値として, 学習を行なった.

次に, 用いたデータセットを表 3 に示す. データセット中の各画像に対し, 波が届くまでを欠陥なし, それ以後を欠陥ありとして, 2 クラス分類用のデータセットを構成した.

性能評価は次のようにして行った. まず, 計 203 種類の画

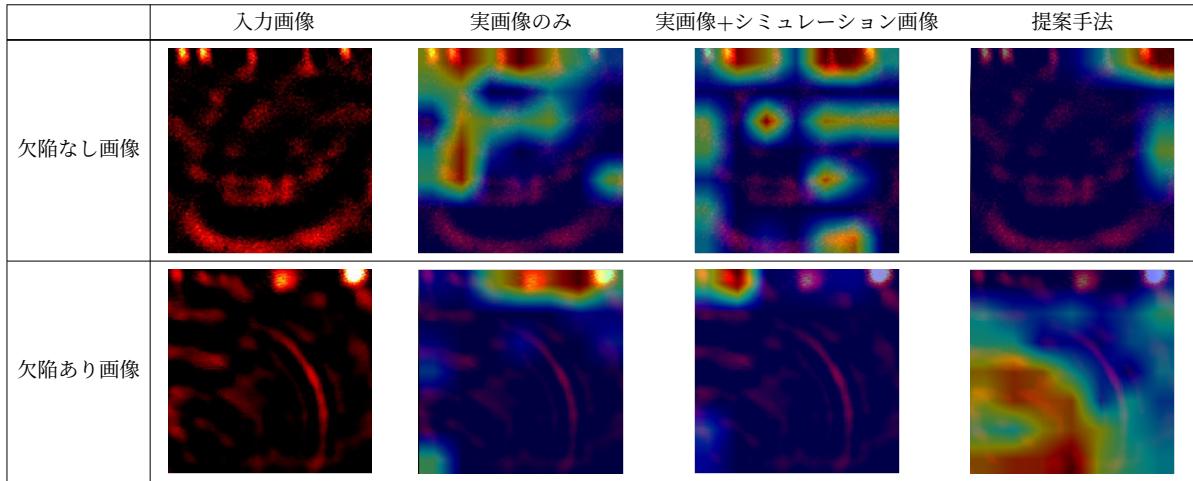
表 4: 画像集合を訓練用データ 61 個, 検証用データ 20 個, 評価用データ 122 個に分割した場合の欠陥検出性能.

データ拡張手法	EfficientNet			ResNeXt			ViT		
	Accuracy	Precision	Recall	Accuracy	Precision	Recall	Accuracy	Precision	Recall
実画像のみ	0.951	0.868	0.826	0.954	0.873	0.842	0.958	0.875	0.869
実画像 + シミュレーション画像	0.949	0.861	0.822	0.950	0.849	0.849	0.961	0.887	0.876
実画像 + スタイル変換画像 (提案手法)	0.961	0.899	0.859	0.963	0.881	0.895	0.968	0.900	0.903

表 5: 画像集合を訓練用データ 41 個, 検証用データ 20 個, 評価用データ 142 個に分割した場合の欠陥検出性能.

データ拡張手法	EfficientNet			ResNeXt			ViT		
	Accuracy	Precision	Recall	Accuracy	Precision	Recall	Accuracy	Precision	Recall
実画像のみ	0.935	0.810	0.789	0.940	0.834	0.792	0.945	0.858	0.800
実画像 + シミュレーション画像	0.937	0.813	0.806	0.933	0.811	0.777	0.951	0.854	0.850
実画像 + スタイル変換画像 (提案手法)	0.940	0.825	0.821	0.949	0.844	0.847	0.956	0.871	0.864

表 6: Grad-CAM によるクラス活性化マッピング. 欠陥なし画像に対する予測を上段に, 欠陥あり画像に対する予測を下段に示す. それぞれの画像を正しく分類できたのは, 提案手法のみである.



像集合を訓練用データ, 検証用データ, 評価用データに分割した. 訓練用データはモデルを学習するために用いた. そして, エポックごとに検証用データでの損失を記録し, そのうち損失を最小する重みを学習結果として選択した. 学習で得られた重みを用い, 評価用データでの Accuracy, Precision, Recall の値を算出した. 以上の手続きをデータの分割パターンを変えて 5 回繰り返し, それぞれの評価指標について平均をとることで, 最終的な結果とした.

5.2.2 実験結果

実 LUVT 画像の画像集合を訓練用データ 61 個, 検証用データ 20 個, 評価用データ 122 個に分割した場合を, 表 4 に示す. まず, 提案法以外の場合について観察する. モデルが ViT の場合では, Accuracy, Precision, Recall ともに, シミュレーションによるデータ拡張で, 欠陥検出性能が向上している. 一方, EfficientNet と ResNeXt では, シミュレーション画像でデータ拡張を行うことで, かえって欠陥検出性能を低下させている. すなわち, 直接シミュレーション画像を用いて, データ拡張を行うことは一部のモデルに対しては, 有用でないことを示唆している. これに対して, 提案手法について着目すると, どのモデルにおいても, 有意に欠陥検出性能が向上している.

次に, 実 LUVT 画像の画像集合を訓練用データ 41 個, 検証用データ 20 個, 評価用データ 142 個に分割し, 訓練用データ数を減らした場合についての結果を表 5 に示す. この結果から, 元の訓練用データセットがより小規模なデータセットな場合においても, 提案手法を用いてモデルを訓練することで, 欠陥の誤検出と見逃しを抑制することができた.

5.2.3 判断根拠の可視化

前節では, 提案手法が欠陥の分類性能を向上させたことを報告した. 本節では, Grad-CAM [11] を用いて, モデルの予測結果についての分析を行う.

学習された EfficientNet を用いて, LUVT 画像を分類した際のクラス活性化マッピングを, 表 6 に示す. 欠陥なしに対する予測例では, 提案手法に関しては欠陥なしと正しく判定できている. これに対して提案法以外では, 画像の欠陥がない箇所に対して, モデルが注視してしまっている. 特にこの傾向は, 波紋が欠陥とは無関係に乱れてしまっている場合に確認できた. 一方, 欠陥ありに対する予測例では, 提案手法以外では, おおよその欠陥の位置について注視できていない. モデルの予測結果から, これらは欠陥の見逃しになっており, 非破壊検査においては特に避けなければならない. これに対し, 提案手法の結

果を観察すると、欠陥の周辺を注視している上に、実際の予測結果も欠陥ありと正しく予測ができていた。よって、提案手法を用いることで、LUVT 画像から欠陥の有無をより正しく判別できていることが確認できる。

6 結 論

本論文では、LUVT におけるシミュレーション画像にスタイル変換を施し、データ拡張を行う手法を提案した。LUVT で得られた画像から深層学習で欠陥検出することを試みるが、LUVT 画像の収集には多くの費用と時間を要するため、大規模な訓練用データが利用できない。この課題を解決するため、多様かつ大規模なシミュレーション画像を訓練用データとして活用することを考えた。しかし、シミュレーション画像のスタイルは実際に測定された LUVT 画像のスタイルとは異なるため、スタイル変換と呼ばれる技術により、シミュレーション画像のスタイルを、LUVT 画像のスタイルに近づけることで、データ拡張を行った。数値実験から、シミュレーション画像にスタイル変換を施し、データ拡張を行うことで、欠陥の分類性能を向上させることを確認した。

LUVT 自体はまだ発展途上であり、改良が進められている。今後の課題には、測定装置の発展に伴って出現が見込まれる、より挑戦的な機械学習課題への取り組みがあげられる。

謝辞：本研究の一部は、公益財団法人セコム科学技術振興財団一般研究助成により実施された。また、JSPS 科研費 19K04661 の助成を受けた。

文 献

- [1] Yasmina Al Khalil, Sina Amirrajab, Cristian Lorenz, Jürgen Weese, Josien Pluim, and Marcel Breeuwer. On the usability of synthetic data for improving the robustness of deep learning-based segmentation of cardiac magnetic resonance images. *Medical Image Analysis*, 84:102688, 2023.
- [2] Christopher Bowles, Liang Chen, Ricardo Guerrero, Paul Bentley, Roger Gunn, Alexander Hammers, David Alexander Dickie, María Valdés Hernández, Joanna Wardlaw, and Daniel Rueckert. Gan augmentation: Augmenting training data using generative adversarial networks, 2018.
- [3] Terrance DeVries and Graham W Taylor. Improved regularization of convolutional neural networks with cutout. *arXiv preprint arXiv:1708.04552*, 2017.
- [4] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [5] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672–2680, 2014.
- [6] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, and Alexei A Efros. Image-to-image translation with conditional adversarial networks. In *Computer Vision and Pattern Recognition (CVPR), 2017 IEEE Conference on*, 2017.
- [7] Dongjie Liu, Jin Zhao, Axing Xi, Chao Wang, Xinnian Huang, Kuncheng Lai, and Chang Liu. Data augmentation technology driven by image style transfer in self-driving car based on end-to-end learning. *Computer Modeling in Engineering & Sciences*, 2020.
- [8] Min Meng, Yiting Jacqueline Chua, Erwin Wouterson, and Chin Peng Kelvin Ong. Ultrasonic signal classification and imaging system for composite materials via deep convolutional neural networks. *Neurocomputing*, 257:128–135, 2017. Machine Learning and Signal Processing for Big Multimedia Analysis.
- [9] Saman Motamed, Patrik Rogalla, and Farzad Khalvati. Data augmentation using generative adversarial networks (gans) for gan-based detection of pneumonia and covid-19 in chest x-ray images. *Informatics in Medicine Unlocked*, 27:100779, 2021.
- [10] Luka Posilović, Duje Medak, Fran Milković, Marko Subašić, Marko Budimir, and Sven Lončarić. Deep learning-based anomaly detection from ultrasonic images. *Ultrasonics*, 124:106737, 2022.
- [11] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336–359, oct 2019.
- [12] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [13] Jie Tan, Tingnan Zhang, Erwin Coumans, Atil Iscen, Yunfei Bai, Danijar Hafner, Steven Bohez, and Vincent Vanhoucke. Sim-to-real: Learning agile locomotion for quadruped robots. 2018.
- [14] Mingxing Tan and Quoc Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 09–15 Jun 2019.
- [15] Chien-Yao Wang, Alexey Bochkovskiy, and Hong-Yuan Mark Liao. Scaled-yolov4: Scaling cross stage partial network. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 13029–13038, June 2021.
- [16] Saining Xie, Ross B. Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. *CoRR*, abs/1611.05431, 2016.
- [17] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix: Regularization strategy to train strong classifiers with localizable features. In *International Conference on Computer Vision (ICCV)*, 2019.
- [18] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. In *International Conference on Learning Representations*, 2018.
- [19] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Computer Vision (ICCV), 2017 IEEE International Conference on*, 2017.
- [20] 中島 未椰, 斎藤 隆泰, and 加藤 毅. レーザー超音波可視化試験における欠陥検出のための深層 CNN 構造の検討. AI・データサイエンス論文集, 3(J2):916–924, 2022.
- [21] 斎藤 隆泰. 境界要素法 (BEM) を用いた超音波シミュレーション. *Journal of the Japanese Society for Non-destructive Inspection*, 60(4):210–215, 04 2011.
- [22] 斎藤 隆泰. 波動解析と時間領域境界要素法. *Journal of the Japan Society for Computational Engineering and Science*, 24(3):3935–3938, 2019.