

# 人のパーソナリティと場所の特徴を用いた ストレス推定と推定根拠の説明

狭間亮太郎<sup>†</sup>    和田 真弥<sup>††</sup>    瀧田 慎<sup>†</sup>    大島 裕明<sup>†</sup>

<sup>†</sup> 兵庫県立大学社会情報科学部    〒 651-2197 兵庫県神戸市西区学園西町 8-2-1

<sup>††</sup> 株式会社 KDDI 総合研究所    〒 356-8502 埼玉県ふじみ野市大原 2-1-15

E-mail: <sup>†</sup>fa19x0648@guh.u-hyogo.ac.jp, <sup>††</sup>sh-wada@kddi.com, <sup>†††</sup>takita@sis.u-hyogo.ac.jp,  
<sup>††††</sup>tohshima@ai.u-hyogo.ac.jp

**あらまし** 本研究では、人のパーソナリティと場所の特徴を用いてストレスの推定と推定根拠の説明を行う。提案するストレス推定モデルでは、人のパーソナリティと場所の特徴を入力とし、ストレス値を出力する。人のパーソナリティは TIPI-J と GHQ30 と呼ばれる質問紙を用いて測定する。場所の特徴は TripAdvisor から得られるレビュー文を用いる。レビュー文は場所の特徴を含むテキストデータであるため、BERT を用いて 768 次元の特徴ベクトルを取得し、これを利用する。ストレス値には心拍変動係数である LF/HF 値を用いる。評価実験では、特定の場所において提案手法がストレス推定に有効である結果が得られた。得られた推定結果の解釈には LIME を利用した。LIME を用いて場所の特徴がストレス推定に及ぼす影響を可視化し、推定根拠の考察を行った。

**キーワード** ストレス推定, 信号処理, 言語処理, 説明可能性

## 1 はじめに

現代社会において、我々は様々な状況で精神的なストレスを受け、それらを避けて通ることは難しい。例えば、職場で上司から注意を受けるときや、重要な会議での発表が差し迫ったときはストレスを受ける状況といえる。

そこで重要になるのが、自発的なストレスの解消である。人はストレスを溜めすぎると自律神経失調症やうつ病といった心の病にかかる可能性がある。そのため、自身の心身の状態に気を配り、自発的にストレスの解消に取り組む必要がある。

ストレスの解消には、自分に適した場所への訪問が効果的である。例えば、仕事に疲れたときに、森林浴や神社を訪れることが適している人もいれば、自宅近くの静かな喫茶店を訪れることが適している人もいる。

しかし、普段訪れることのない未知の場所が自分に適しており、ストレスを解消できるかどうかを把握することは難しい。

把握が難しい原因として、人によるストレスの受け方の違いがある。人それぞれストレスの受け方が異なるため、ストレス解消の方法も人によって異なる。ある場所において、ストレスを解消できる人もいれば、そうでない人も存在する。例えば、人通りの多い商店街において、ストレスを解消する人もいれば、ストレスを受ける人もいる。このような、人によって異なるストレスの受け方は、人のパーソナリティが影響していると考えられる。例えば、他人との交流を好み、街の喧噪を苦に思わない人であれば、賑やかな商店街においてストレスの解消が期待できる。一方、普段は一人で過ごすことを好み、静かで落ち着いた場所を好む人にとっては賑やかな商店街においてストレスを感じる場所である可能性が高い。

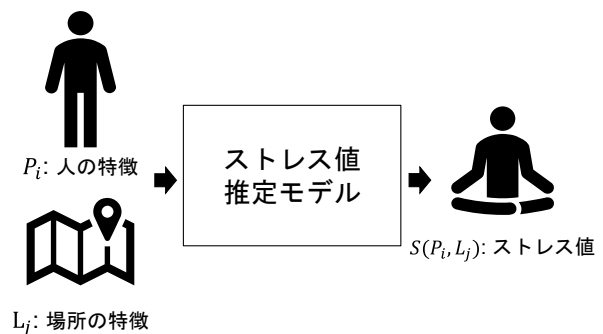


図1 提案するストレス推定モデルの概要

また、未知の場所においてストレスを解消できるかの把握には、こういった場所なのかを考慮する必要があります。場所の特徴とは、例えば、「人が少なく、静かで自然があふれる場所」といった情報である。こういった場所の特徴は人が受けるストレスに影響を与えていると考えられる。

そこで、本研究ではこういったパーソナリティの人が、こういった特徴のある場所でストレスを解消できるかを推定する手法を提案する。人のパーソナリティと場所の特徴を入力にストレス値を出力するモデルの概要を図1に示す。なお、本研究は兵庫県立大学情報科学研究科研究倫理委員会の研究倫理審査申請を行い承認を得た後、実施した。(承認番号: UHGSIS-EC-2022-007) 本研究の目的は、人のパーソナリティ、場所の特徴、ストレスの間に存在する関係性を明らかにすることである。機械学習により作成したストレス推定モデルは人のパーソナリティ、場所の特徴、ストレスの関係性を明らかにする手段として有効な可能性がある。説明可能性の手法を用いた推定根拠の説明は機械学習によって得られた関係性を明らかにするために利

用する。

## 2 関連研究

### 2.1 パーソナリティの測定

パーソナリティの測定は質問紙を用いて「勤勉性」や「外向性」といった心理的な特徴をあらわす性質（パーソナリティ特性）を評価する手法が一般的である。質問紙とは、心理検査や社会調査で、調査項目を質問として掲載した用紙である。

BigFive は Goldberg ら [4], [5] によって提案されたパーソナリティ特性の理論である。BigFive は基本的なパーソナリティを 5 つの因子で分析するモデルであり、NEO-PI-R や TIPI といった質問紙で採用されている。以下に 5 つの因子を示す。

- Extroversion 外向性
- Agreeableness 協調性, 調和性
- Conscientiousness 勤勉性, 誠実性
- Neuroticism 神経症傾向, 情緒不安定性
- Openness to Experience 開放性

TIPI は Gosling ら [8] によって提案された質問紙である。TIPI は 10 項目の質問で構成され、BigFive の 5 つの因子をそれぞれ 2 つの質問項目で分析する。短時間で計測を行うことができ、医療現場や心理学の実験に至るまで広範な領域で利用されている。日本語版には小塩ら [20] によって作成された TIPI-J がある。TIPI-J は質問項目が少なく、被験者への負担も小さいことから、心理実験等で広く活用されている。本研究でも TIPI-J を用いてパーソナリティ分析を行う。

### 2.2 心理的ストレス反応の測定

心理的ストレス反応とは、ストレスに関連する身体的心理的な症状や不調のことを指す。心理的ストレス反応の測定は自己記入式の質問紙が用いられる。

Goldberg ら [6] が提案した The General Health Questionnaire (GHQ) は 60 の質問項目で構成されており、身体的症状や不安と不眠、社会的活動障害、うつ傾向の 4 つの因子を評価する。精神疾患や神経症の有無を判別するために用いられる。日本版 GHQ 精神健康調査法は中川ら [3] によって作成された GHQ を日本語に翻訳した質問紙である。日本での精神健康調査に利用され、精神疾患や神経症の有無を判別するために用いられる。GHQ は短縮版が開発されており、本研究では 30 の質問項目で構成される GHQ30 を利用する。GHQ30 は以下の 6 つの因子を 30 の質問項目で評価する質問紙であり、因子分析等で、許容範囲内の評価が得られ妥当性が示されている [10]。

- 一般的疾患傾向
- 身体的症状
- 睡眠障害
- 社会的活動障害
- 不安と気分変動
- 希死念慮

GHQ30 は質問項目が少なく、被験者への負担が少ないことから、臨床現場や心理学実験など幅広い領域で利用される。本




図 2 心電図における QRS 波と R-R interval

研究では、人の日常生活におけるストレス反応を事前に把握するために GHQ30 を用いる。

### 2.3 ストレス評価指標としての心拍変動

ストレス評価指標として心拍や呼吸といったバイタルサインの他、唾液や血液といった生体試料を用いる手法がある [24], [25]。中でも、比較的測定しやすく、ストレス評価指標として最も用いられているのが心拍変動である。心拍変動は生体試料の採取が不要である点や、短時間の自律神経活動の変化からストレス状態を推定できる点が優れているとされる [18]。

心拍変動は心拍と心拍の時間差 (RRI) から算出される。RRI の概要を以下の図 2 に示す。RRI の測定に、通常は心電計が用いられる。しかし、一般的に心電計が簡易な計測に適していないことから、多くの場合、代替手段として脈波計が用いられる。脈波計から得られるピークピーク間隔 (PPI) もまた RRI と同様に心拍変動を求める際に利用できる [19]。

心拍変動は、自律神経における交感神経と副交感神経の活動状態を反映することが知られており、自律神経の分析に用いられる [16]。心拍変動を用いた自律神経の評価指標に LF/HF 値がある。LF/HF 値は心拍変動を周波数解析することで得られる指標であり、自律神経系における交感神経活動と副交感神経活動のバランスを表す。また、LF/HF 値は生体のストレス反応を評価する指標として広く用いられている [21], [22]。そのため、本研究では LF/HF 値をストレス評価指標として用いる。

### 2.4 ストレス推定研究

ストレスの推定を行う研究では、センサから得られた生理学的反応を分析、推定する手法が提案されている。

Joseph ら [1] は、ドライバーが 1 分後に感じるストレスを足と手の皮膚電気信号 (GSR) および、胸部からの呼吸と心電図 (ECG) 信号から推定する手法を提案した。推定にはランダムフォレストを利用し、実験によって得られたテストデータを用いて 94 % の平均精度を記録した。

Kizito ら [13] は、個人にパーソナライズしたストレスモニタリング手法を提案した。推定には RandomForest および ExtraTrees モデルを利用した。学習データには SWELL [11] と WESAD [15] のデータセットを用いた。実験では、PPG および EDA のデータをリストバンド型センサデバイスを用いてデータを収集し、推定精度は 95 % となっている。

吉村ら [23] は観光地でのストレス推定モデルを提案した。提案したストレス推定モデルは人のパーソナリティと観光地のレビュー文を用いてストレスを推定するモデルである。ストレス

評価値には 2.3 節で紹介した LF/HF 値を利用している。推定モデルは BERT をベースとしたニューラルネットワークの分類器である。実験では、神戸市の観光地を対象にデータの収集を行い、テストデータを用いた推定精度は 86 % となっている。しかし、学習の際に用いた観光地データがテストデータにも含まれており、推定モデルの評価として適切でない可能性がある。

本研究では、吉村らの研究を再検証し、観光地におけるストレス推定モデルの適切な評価を行う。また、推定根拠の説明に取り組む点で吉村らの研究とは異なる。

## 2.5 機械学習モデルの解釈手法

近年は、深層学習を用いた業務効率化や意思決定の補助が盛んに行われている。しかし、深層学習は人間にとっての理解が難しいことからブラックボックスと言われ、推定のプロセスや推定結果の根拠を示すことが課題である。そんな中、深層学習のブラックボックスの解釈性を向上させる手法や研究が進められている [17]。

LIME (Local Interpretable Model-Agnostic Explanation) は Marco ら [14] によって提案された手法である。LIME は機械学習モデルの解釈に利用され、入力データが推定結果に与える影響を評価できる。機械学習モデルは、線形モデルから非線形モデルまで幅広く利用でき、入力データの種類としてはテーブルデータ、テキスト、画像を利用できる。LIME は一つの入力データに対して説明する手法のため、局所的な説明手法と呼ばれる。

Dina ら [12] は、テキストデータに対する LIME の解釈妥当性を検討した。実験では線形モデルおよび決定木について妥当性を明らかにしたのち、深層学習において意味のある説明を出力する可能性があると結論付けている。本研究では、提案するストレス推定モデルを LIME で分析し、場所の特徴として用いるレビュー文のストレス推定への影響を評価する。

## 3 人と場所の特徴を用いたストレス推定手法

本節では、本研究における提案手法について述べる。本研究では、人と場所の特徴を用いてストレスの推定に取り組む。ストレスの推定には機械学習モデルを利用し、モデルの学習には、人のパーソナリティと場所の特徴、ストレス値の 3 つのデータを利用する。本節のセクションにおいて、利用するデータの詳細を述べる。その後、提案するストレス推定モデルについて述べる。

### 3.1 人の特徴と特徴ベクトルの作成

人の特徴とストレス推定モデルで利用する人の特徴ベクトルについて述べる。まず、本研究での人の特徴とは、人のパーソナリティのことを言う。人のパーソナリティは心理学の分野で調査や研究が盛んであり、一般的に、2.1 節や 2.2 節で述べた質問紙によって質的に評価する。人のパーソナリティは外向性や協調性といった複数の因子で分析され、質的な評価では、質問紙の回答からそれぞれの因子について得点を算出する。本研究では、2.1 節で述べた TIPI-J と 2.2 節で述べた日本語版

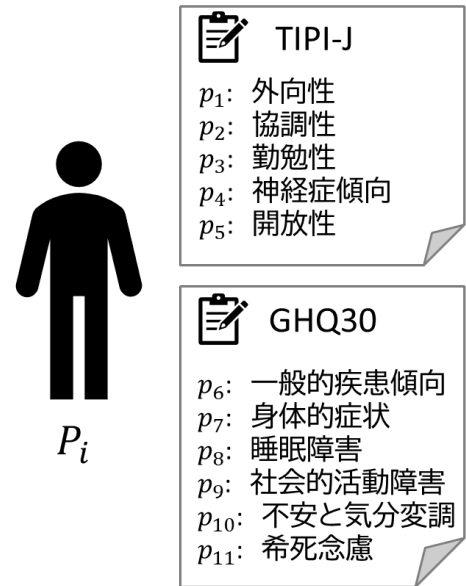


図 3 人の特徴とパーソナリティ因子

GHQ30 を用いて人のパーソナリティを評価する。評価する因子を図 3 に示す。

TIPI-J は 10 項目の質問から構成され、外向性 (Extraversion)、協調性 (Agreeableness)、勤勉性 (Conscientiousness)、神経症傾向 (Neuroticism)、開放性 (Openness) の 5 つの因子をそれぞれ 2 つの質問項目で評価する。それぞれの質問に「全く違うと思う」から「強くそう思う」まで 7 段階で回答を行い、回答結果から 5 つの因子にそれぞれ -6 点から 6 点の得点を付けて評価する。本研究では、5 つの因子における得点を -1 点から 1 点に正規化を行い、因子得点とする。

日本語版 GHQ30 は 30 項目の質問から構成され、一般的疾患傾向、身体的症状、睡眠障害、社会的活動障害、不安と気分変調、希死念慮とうつ傾向の 6 つの因子をそれぞれ 5 つの質問項目で評価する。評価は GHQ 法で行い、それぞれの因子に 0 点から 5 点の得点を割り振る。本研究では 6 つの因子における得点を -1 点から 1 点に正規化を行い、これを因子得点とする。

人の特徴ベクトル  $P_i$  は図 3 に示す項目の  $p_1$  から  $p_{11}$  までの因子得点を横に結合し、以下の 11 次元のベクトルで表す。

$$P_i = (p_1^i, p_2^i, \dots, p_{10}^i, p_{11}^i)$$

ここで作成した人の特徴ベクトルはストレス推定モデルで利用する。

### 3.2 場所の特徴と特徴ベクトルの作成

場所の特徴とストレス推定モデルで利用する場所の特徴ベクトルの作成について述べる。まず、本研究では場所の特徴としてレビュー文を用いる。 $n$  件のレビュー文  $r_k$  が存在する場所の特徴  $L_j$  は以下の集合で表す。

$$L_j = \{r_1^j, r_2^j, \dots, r_k^j, \dots, r_{n-1}^j, r_n^j\}$$

次に、本研究で扱う場所の特徴ベクトルについて述べる。場所の特徴  $L_j$  は集合であり、その要素であるレビュー文  $r_k^j$  はテ




図 4 場所の特徴ベクトルの抽出




図 5 相対的なストレス値

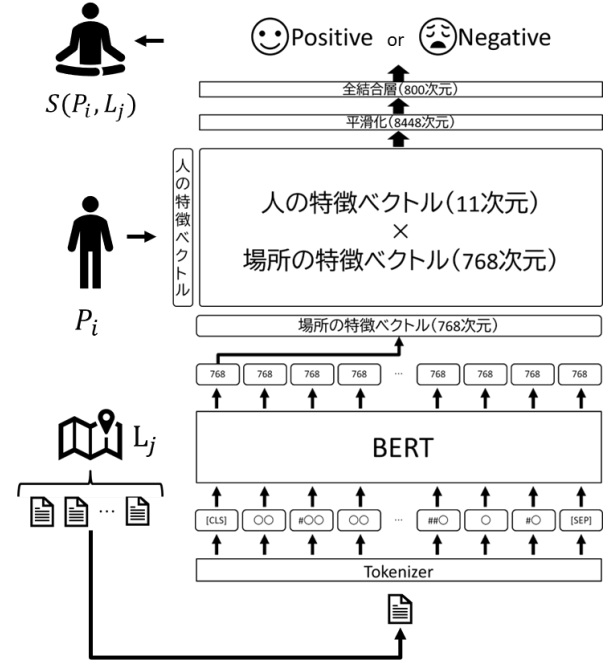


図 6 ストレス推定モデルの全体構造

キストデータである。テキストデータから文脈情報を考慮した特徴ベクトルを抽出する手法として BERT がある [2]。任意のレビュー文  $r_k^j$  を BERT に入力することで、レビュー文  $r_k^j$  から特徴ベクトル  $h_k^j$  を得る。場所の特徴ベクトルを取得する流れを図 4 に示す。

本研究では、BERT を用いて得られたレビュー文  $r_k^j$  の特徴ベクトルを場所の特徴ベクトルと呼び、ストレス推定モデルに利用する。

### 3.3 ストレス値の作成

ストレス値の作成について述べる。本研究では、ストレス指標として 2.3 節で触れた心拍変動係数の LF/HF 値を用いる。LF/HF 値は人によって取りうる値の範囲が異なり、数値のみでその人のストレス状態を判断することは難しい。そこで、LF/HF 値を各個人で相対的な値に変換し、ストレス値として利用する。本研究におけるストレス値はその人の LF/HF 値が中央値未満 (Positive)、または、中央値以上 (Negative) の 2 値データとする。

### 3.4 ストレス推定モデルの構造

ストレス推定モデルの構造について述べる。ストレス推定モデルは大きく二つの部分からなる。一つは、3.2 節で述べた場所のレビュー文から場所の特徴ベクトルを取得する部分。もう一つは、3.1 節で述べた人の特徴ベクトルと、BERT から出力された場所の特徴ベクトルの外積部分であり、ここでは、人の特徴と場所の特徴の兼ね合いを考慮した行列を作成した。ストレス推定モデルの全体構造を図 6 に示す。  $P_i$  は人の特徴であり、  $L_j$  は場所の特徴を表す。

場所の特徴  $L_j$  は  $n$  個のレビュー文  $r_k^j$  の集合である。レビュー文の内、任意のレビュー文  $r_k^j$  を選択し、Tokenizer を用いて、トークン化を行う。トークン化されたレビュー文から BERT を

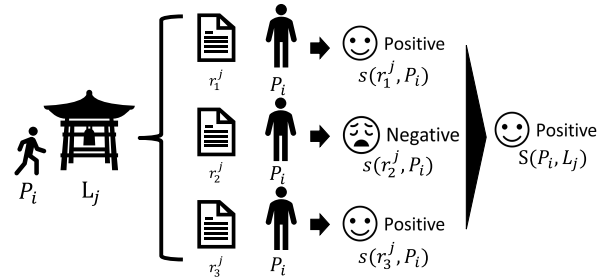


図 7 場所の特徴を用いた多数決によるストレス値推定

用いて場所の埋め込みを獲得する。この場所の特徴を表す埋め込みと 11 次元のパーソナリティ  $P_i$  のそれぞれの積を求める。これを分類層に渡し  $s(P_i, r_k^j)$  を得る。これを、  $L_j$  のすべての要素に対して行う。  $s(P_i, r_k^j)$  で多数決を行うことで、ある人の  $p_i$  のパーソナリティ  $P_i$  がある場所の特徴  $L_j$  で感じるストレス  $S(P_i, L_j)$  を求める。図 7 はある場所のレビューごとで推定されたストレス値の多数決によって、場所全体としてのストレス値を決定する概念図である。

$$S(P_i, L_j) = \{s(P_i, r_k^j) | k = 1, 2, \dots, n-1, n\}$$

この多数決では、  $s(P_i, r_k^j)$  で Positive が過半数である場合に  $S(P_i, L_j)$  を Positive、  $s(P_i, r_k^j)$  で Negative が過半数である場合に  $S(P_i, L_j)$  を Negative と推定する。

## 4 実験

本研究では、2022 年 12 月から 2023 年 1 月にかけて神戸市の観光地を対象に実験をおこなった。実験において、被験者は事前に 3.1 節で述べたパーソナリティ調査のアンケートに回答した後、対象となる観光地で心拍データの計測および対象の場所について尋ねるアンケートを実施した。本節のセクションで

表 1 対象とした観光地

番号	観光地名
1	布引の滝
2	神戸北野天満宮
3	神戸異人館
4	神戸ムスリムモスク
5	生田神社
6	三宮センター街ショッピングストリート
7	三宮神社
8	神戸旧居留地
9	中華街南京町
10	神戸元町商店街
11	元町高架通商店街
12	神戸ハーバーランド umie
13	街角遊園地モザイクガーデン
14	メリケンパーク
15	神戸震災メモリアルパーク
16	神戸市立博物館
17	東遊園地公園
18	小野八幡神社
19	さんちか
20	ミント神戸



図 8 心拍データ測定システム



図 9 実験の流れ

は、実験の条件について説明し、条件を設定した動機や理由について説明する。

#### 4.1 対象とした被験者

実験の募集は大学の学生と教員を中心に行い、心身ともに健康な男性 13 人、女性 7 人の合計 20 人の被験者が参加した。実験の参加に際して、被験者には実験の内容や個人情報の保護について説明し、書面で実験参加の同意を得た。なお、本研究は兵庫県立大学情報科学研究科研究倫理審査の承認を得ている。(承認番号: UHGSIS-EC-2022-007)

#### 4.2 対象とした観光地

本研究では、神戸市中央区周辺に位置する観光地を対象に実験を行った。観光地の選択の際は、TripAdvisor<sup>1</sup>において 20 件以上のレビューが投稿されていることを条件とした。対象とした場所を表 1 に示す。

#### 4.3 技術的設定

実験では、心拍データを収集する。収集には、心拍センサを利用し、心拍センサからデータを記録するシステムを開発した。ここでは、心拍データを収集するシステムについて述べる。心拍データの収集には心拍センサ (SEN-11574, SparkFun) を用いる。この心拍センサは皮膚に緑色の光を照射し、その反射量の変化を測定することで、心拍データを取得する。センサから得られた心拍データは M5Stack Basic を用いて記録する。ここで、心拍センサと M5Stack Basic を接続したシステムを心拍データ測定システムと呼ぶ。心拍データ測定システムを図 8 に示す。システムは取得した心拍データをリアルタイムで画面

に表示し、5 分間の心拍データを microSD カードに保存する機能を持つ。

#### 4.4 実験の流れ

実験は大きく 2 つのフェーズがある。実験の流れを図 9 に示す。

1 目目のフェーズでは、3.1 節で述べた TIPI-J および日本語版 GHQ30 の 2 つアンケートによるパーソナリティ調査を実施する。今回の実験において、質問への回答および収集はオープンソースオンライン統計調査 Web アプリの Limesurvey<sup>2</sup> を利用した。

2 目目のフェーズでは、4.2 節で述べた 20 か所の観光地において心拍データの測定を実施する。心拍データの測定には 4.3 節で述べた心拍データ測定システムを用いる。測定は立位姿勢で行う。実際の測定の様子を図 10 に示す。心拍データの測定は指定した場所へ移動した後に 10 分間で実施する。被験者には、指定した場所に移動してもらったのち、最初の 3 分間は安静期間とする。これは、心拍データの測定にその場所までの移動による影響を受けないようにするためである。

#### 4.5 心拍データの解析

心拍変動解析には、4.3 節で述べた心拍データ測定システムから収集された心拍データを利用する。ただし、心拍データ測定システムは機器の性質上、体動や光の影響を受ける。そのため、心拍変動解析を行うにあたり、これらの影響を除去する必要がある。ここでは、心拍データの外れ値処理と、LF/HF 値

1: <https://www.tripadvisor.jp/>

2: <https://www.limesurvey.org/>





図 10 測定の様子

算出の流れを説明する。LF/HF 値の計算には、Python のライブラリである pyHRV を用いた [7]。

心拍データからピークを検出する方法について述べる。心拍データ測定システムから得られた心拍データから心拍波形におけるピーク検出を行う。ピーク取得の概要を図 11 に示す。ピークの検出の前処理として、システムで計測できなかった心拍波形からノイズの除去を行う。心拍波形には通常ノイズ（高周波成分）が混ざっており、ピークの誤検知を引き起こす要因である。そのため、心拍データから移動平均をとり心拍波形からノイズの除去を行う。本研究では、窓サイズ 300 ミリ秒の移動平均を心拍データに適用した。

ピーク検出の手順を説明する。まず、ある時点  $t$  の心拍データを  $h_t$  とし。  $t-500$  から  $t+500$  まで、1000 ミリ秒間の心拍データ  $H_t$  を以下のように表す。

$$H_t = (h_{t-500}, h_{t-499}, \dots, h_{t+499}, h_{t+500})$$

ここで、心拍データ  $h_t$  が  $H_t$  の四分位範囲において閾値 0.8 を上回るとき、心拍データ  $h_t$  をピーク候補  $C$  とする。ピーク候補  $C$  は以下のように表す。

$$C = (h_t, h_{t+1}, \dots, h_{t+n-1}, h_{t+n})$$

ある時点  $t+n+1$  において心拍データ  $h_{t+n+1}$  は  $H_{t+n+1}$  の四分位範囲における閾値 0.8 を下回り、心拍データ  $h_{t+n+1}$  はピーク候補  $C$  でなくなる。ピーク候補がなくなった時点  $t_a+n+1$  で、ピーク候補  $C$  を探索し、最も高くなった心拍データ  $\max(C)$  をピーク  $peek_t$  として検出する。また、実際にピークを検出した心拍波形を図 12 に示す。

ストレスの測定について説明する。心臓は微妙な変動を繰り返し拍動している。この微妙な変動を心拍ゆらぎと呼ぶ。心拍




図 11 ピーク検出の概要図

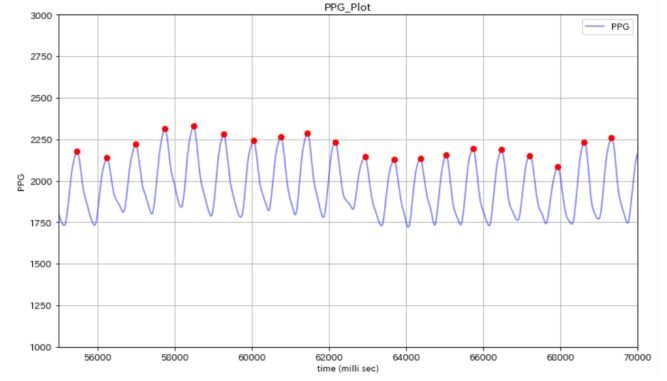


図 12 ピークを検出した心拍データ

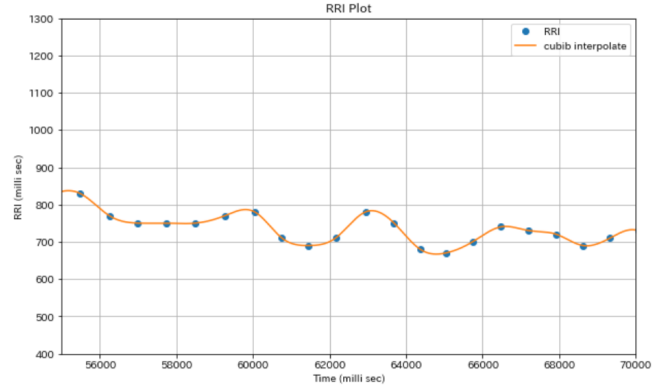


図 13 RRI プロット

ゆらぎは、身体的な精神的なストレスの変化を反映しており、ストレスの指標に用いられる。心拍ゆらぎは、拍動と拍動の時刻差（RRI）を時系列で並べることで表現できる。RRI を時系列で並べたものをここでは RRI 列と呼ぶ。RRI 列から心拍ゆらぎを可視化する方法に RRI プロットがある。RRI プロットの横軸は心臓が拍動した時刻をとり、縦軸は一つ手前の拍動との時間差をとる。可視化したものを図 13 に示す。

RRI 列は自律神経の働きが影響していることが知られており、RRI 列を周波数解析することで自律神経の働きを評価できる。本研究では、2.3 節で取り上げた LF/HF 値を RRI 列を用いて計算し、ストレス指標として用いる。

## 5 結 果

人と場所の特徴からストレス値を推定した結果について述べる。本節のセクションでは、推定に利用した TripAdvisorBERT




図 14 TripAdvisorBERT の学習経過曲線

ついて述べ、その後、推定結果について述べる。

## 5.1 TripAdvisorBERT

BERT は Google AI Language が発表した汎用自然言語モデルであり、テキストを入力に文脈を考慮した特徴ベクトルを出力する。BERT は Masked Language Modeling (MLM) および Next Sentence Prediction (NSP) の 2 つのタスクに取り組むことでテキストから文脈を考慮した特徴表現を獲得することに成功した。上記の学習は事前学習と呼ばれる。

事前学習で用いられる MLM は、追加で行うことで、特定のドメインにおける分類や回帰のタスクでより高い推論性能を獲得できると報告されている [9]。そのため、本研究において、日本語 Wikipedia で事前学習を行った東北大学 BERT<sup>3</sup>に、TripAdvisor のレビュー特徴を追加で学習した TripAdvisorBERT を作成し、ストレス推定モデルに利用した。

TripAdvisorBERT の作成には、TripAdvisor に掲載されている 53,180 件のレビュー文を用いた。MLM を行った際の設定を以下に示す。また、MLM の学習経過曲線を図 14 に示す。

- 訓練データ: 53,180
- バッチサイズ: 8
- 学習率: 2e-6
- 入力長: 127

## 5.2 ストレス推定モデルの性能

ストレス推定モデルを用いた推論の結果について掲載する。ストレス推定モデルは、5.1 節で述べた TripAdvisorBERT に分類問題を解くニューラルネットワークの層の積み重ねた構造である。ファインチューニングでは、分類タスクの学習を行う。この時、TripAdvisorBERT の内部パラメータ含め、ネットワーク全体を学習する。学習には実験で得られた 8000 件のデータを利用し、ファインチューニングは以下の設定で行った。

- 訓練データ: 7,600
- テストデータ: 400
- 学習率: 2e-5
- バッチサイズ: 32
- 入力長: 128

性能を適切に評価するため、訓練データとテストデータで場所が重複しないように分離し、分類器を作成した。神戸市の「三宮センター街ショッピングストリート」をテストデータとした際、推定性能は正解率 0.70、適合率 0.70、再現率 0.70、F

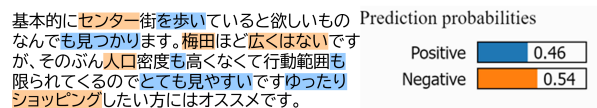


図 15 LIME によってハイライトされたレビュー文

値 0.70 となった。他に、「元町商店街」や「街角遊園地モザイクガーデン」での推定性能は正解率 0.65、F 値 0.65 となった。一方、「中華街南京町」や「ミント神戸」において正解率は 0.50 となり、場所によってはランダム手法と同等の結果も得られた。

## 5.3 LIME を用いた評価

本研究で提案したストレス推定モデルは人のパーソナリティ  $P_i$  と場所の特徴  $L_j$  を用いて、ストレス値  $S(P_i, L_j)$  を推定する深層学習モデルである。そのため、こういった特徴量がストレスの推定に影響しているかを説明することが難しい。そこで、2.5 節で紹介した LIME の手法を用いて、ストレス推定モデルの説明に取り組む。LIME は、Python のライブラリである lime を用いた<sup>4</sup>。

図 15 は「三宮センター街ショッピングストリート」におけるストレス推定結果の一例で、場所の特徴として利用したレビュー文において、ある人のストレスの推定に影響した部分がハイライトされている。青色でハイライトされた部分は、Positive の推定に影響した部分、オレンジでハイライトされた部分は Negative の推定に影響した部分と解釈できる。以下に LIME のパラメータの設定を示す。

- 線形モデルを学習するための近傍サンプル数: 5,000
- サンプルの重み付けに使用する距離指標: cosine

ハイライトされた部分から、「歩く」や「ゆったり」といった単語が Positive に影響しており、「ショッピング」や「センター」が Negative に影響していることがわかる。

## 6 議論

ストレス値の推定性能は個人における Positive, Negative の 2 値分類を観光地ごとで評価した。「三宮センター街ショッピングストリート」や「元町商店街」のように、ある程度推定性能が高い場所がある一方で、「中華街南京町」や「ミント神戸」における推定性能がランダム手法と同等の精度となる場所も確認した。場所によって異なる推定性能が得られた原因として、学習データの不足および相対的なストレス値の扱いの大きく 2 つが影響していると考えられる。

学習データの不足に関して、ストレス値のデータ作成コストが課題である。今回ストレス値として用いた心拍変動係数の LF/HF 値の測定には 4.3 節で述べた心拍データ測定システムを利用した。ただし、このシステムは、機器自体の数に限りがあることや、測定には実際の場所に訪問する必要がある性質上、大量にデータを収集することは困難である。そのため、学習データの不足を解消するためには、現地での心拍データの計測

<sup>3</sup> : <https://github.com/cl-tohoku/bert-japanese>

<sup>4</sup> : <https://github.com/marcotcr/lime>

に代わる、より効率的なデータ収集方法を模索する必要がある。

相対的なストレス値の扱いに関して、本研究では、個人における LF/HF 値の中央値を基準とした Positive, Negative のカテゴリ化を行った。しかし実際のところ、個人の LF/HF 値の分布は正規分布とは異なり、多くの人は右に裾の長い分布となっていたため、中央値以外の基準を設けて 2 値化を行うなど工夫の余地がある。

推定結果の解釈では、LIME を用いて推定に影響を及ぼした部分の可視化を行った。5.3 節に示した例においては、「ゆったり」や「歩く」といった単語が「ストレスが低い」という推定に影響したとわかる。これらの単語は一般的にストレスが低くなる要因と考えられることから、ある程度妥当な推定根拠を提示できたといえる。推定根拠の説明における今後の方向性として、推定根拠の妥当性を適切に評価するために、複数人による解釈結果の妥当性に関する調査や分析を検討する。

## 7 まとめと今後の課題

人のパーソナリティと場所の特徴を用いたストレス推定と推定根拠の説明に取り組んだ。作成したストレス推定モデルでは、特定の場所においてストレスの推定が可能であることを示した。また、LIME を用いた推定結果の解釈について、ある程度納得のできる根拠の提示が可能であることを示した。

今後は、推定性能をより高め、その一方で、高い解釈を行うことのできるストレス推定モデルの作成に取り組む。

## 謝 辞

本研究は JSPS 科研費 JP21H03775, JP18H03244, JP22H03905 の助成を受けたものです。ここに記して謝意を表します。

## 文 献

- [1] Joseph Clark, Rajdeep Kumar Nath, and Himanshu Thapliyal. Machine learning based prediction of future stress events in a driving scenario. In *2021 IEEE 7th World Forum on Internet of Things (WF-IoT)*, pp. 455–458, 2021.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 4171–4186, 2019.
- [3] David P. Goldberg, 泰彬中川, 郁夫大坊. 日本版 GHQ : 精神健康調査票 : 手引. 日本文化科学社, 2013.
- [4] Lewis R. Goldberg. An alternative description of personality: The Big-Five factor structure. *Journal of Personality and Social Psychology*, Vol. 59, No. 6, pp. 12–16, 1990.
- [5] Lewis R. Goldberg. The development of markers for the Big-Five factor structure. *Psychological Assessment*, Vol. 4, No. 1, pp. 26–42, 1992.
- [6] Philip Goldberg. The detection of psychiatric illness by questionnaire. *Maudsley monograph*, 1972.
- [7] Pedro Gomes, Petra Margaritoff, and Hugo Silva. pyHRV: Development and evaluation of an open-source python toolbox for heart rate variability (HRV). In *Proceedings of International Conference on Electrical, Electronic and Computing Engineering (IcETRAN)*, pp. 822–828, 2019.
- [8] Samuel D. Gosling, Peter J. Rentfrow, and William B. Swann Jr. A very brief measure of the big-five personality domains. *Journal of Research in Personality*, Vol. 37, No. 6, pp. 504–528, 2003.
- [9] Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A Smith. Don't stop pretraining: Adapt language models to domains and tasks. *arXiv preprint arXiv:2004.10964*, 2020.
- [10] Felicia A. Huppert, D. E. Walters, N. Day, and B. Jane Elliott. The factor structure of the general health questionnaire (ghq-30): A reliability study on 6317 community residents. *British Journal of Psychiatry*, Vol. 155, No. 2, pp. 178–185.
- [11] Saskia Koldijk, Maya Sappelli, Suzan Verberne, Mark A. Neerincx, and Wessel Kraaij. The swell knowledge work dataset for stress and user modeling research. In *Proceedings of the 16th International Conference on Multimodal Interaction*, pp. 291–298, 2014.
- [12] Dina Mardaoui and Damien Garreau. An analysis of lime for text data. In *Proceedings of The 24th International Conference on Artificial Intelligence and Statistics*, Vol. 130, pp. 3493–3501, 2021.
- [13] Kizito Nkurikiyeyezu, Anna Yokokubo, and Guillaume Lopez. Effect of person-specific biometrics in improving generic stress predictive models. *The Journal of Sensors and Materials*, Vol. 32, No. 2, pp. 703–722, 2020.
- [14] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. “Why should I trust you?” Explaining the predictions of any classifier. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, pp. 1135–1144, 2016.
- [15] Philip Schmidt, Attila Reiss, Robert Duerichen, Claus Marberger, and Kristof Van Laerhoven. Introducing wesad, a multimodal dataset for wearable stress and affect detection. In *Proceedings of the 20th ACM International Conference on Multimodal Interaction*, pp. 400–408, 2018.
- [16] Fred Shaffer and J. P. Ginsberg. An overview of heart rate variability metrics and norms. *Frontiers in Public Health*, Vol. 5, No. 258, pp. 1–17, 2017.
- [17] 亀谷由隆. 説明可能 AI 技術のこれまでとこれから. 電子情報通信学会 技術研究報告, Vol. 121, No. 190, pp. 36–41, 2021.
- [18] 高津浩彰, 宗像光男, 小関修, 横山清子, 渡辺興作, 高田和之. 心拍変動による精神的ストレスの評価についての検討. 電気学会 電気学会論文誌 C (電子・情報・システム部門誌), Vol. 120, No. 1, pp. 104–110, 2000.
- [19] 早野順一郎, 岡田暁宣, 安間文彦. 心拍のゆらぎ: そのメカニズムと意義. 日本人工臓器学会 人工臓器, Vol. 25, No. 5, pp. 870–880, 1996.
- [20] 小塩真司, 阿部晋吾. 日本語版 Ten Item Personality Inventory (TIPI-J) 作成の試み. 日本パーソナリティ心理学会 パーソナリティ研究, Vol. 21, No. 1, pp. 40–52, 2012.
- [21] 松本佳昭, 森信彰, 三田尻涼, 江鐘偉. 心拍揺らぎによる精神的ストレス評価法に関する研究. ライフサポート学会 ライフサポート, Vol. 22, No. 3, pp. 105–111, 2010.
- [22] 高田晴子, 高田幹夫, 金山愛. 心拍変動周波数解析の LF 成分・HF 成分と心拍変動係数の意義. 日本総合健診医学会 総合健診, Vol. 32, No. 6, pp. 504–512, 2005.
- [23] 吉村拓真, 和田真弥, 大島裕明. BERT によるレビュー文からの場所特徴表現とパーソナリティ分析に基づくストレス推定. 第 14 回データ工学と情報マネジメントに関するフォーラム 2022, 2022.
- [24] 田中喜秀, 脇田慎一. ストレスと疲労のバイオマーカー. 日本薬理学会 日本薬理学雑誌, Vol. 137, No. 4, pp. 185–188, 2011.
- [25] 堀輝, 香月あすか, 菅健太郎, 吉村玲児. 客観的なストレス評価方法について. 災害医学会 日本職業・災害医学会会誌, Vol. 66, No. 5, pp. 330–334, 2018.