

地理オブジェクトの位置関係と地物カテゴリに基づく地域特性推定

福地 淳[†] 牛尾 剛聰^{††} 田中 克己^{†††} 角谷 和俊[†]

[†] 関西学院大学総合政策学部メディア情報学科 〒669-1330 兵庫県三田市学園上ヶ原1番

^{††} 九州大学大学院芸術工学研究院 〒815-8540 福岡県福岡市南区塩原4丁目9-1

^{†††} 福知山公立大学 〒620-0886 京都府福知山市字堀3370

E-mail: †{dxd68587,sumiya}@kwansei.ac.jp, ††ushijama@design.kyushu-u.ac.jp,

†††tanaka-katsumi@fukuchiyama.ac.jp

あらまし 近年、ホテルやアパートを予約サイトから選択する例が増えている。ホテルやアパートを決める際は、その周辺が「賑やか」か「閑静」かといった地域特性が重要な判断要因になる。しかし、ユーザがオンライン地図上で地域特性を判断することは困難である。地域特性が周辺の地理オブジェクトのカテゴリや位置関係の影響を受けることに着目し、地理オブジェクトのカテゴリと位置関係から地域特性を予測する手法を提案する。地域特性付き地図画像データセットを構築し、入力した地図画像に対する地域特性の強さを予測する。

キーワード 地理情報、画像認識、地物カテゴリ、観光、不動産

1 はじめに

近年、SUMMO¹や楽天トラベル²などの地物推薦サービスが増加傾向にあり、ホテルや引っ越し先を予約サイトから選ぶことが一般化している。ホテルやアパートを探す際には、ユーザにとって馴染みのない地域の地物を対象とする場合が多い。この場合、周辺環境の地域特性がユーザにとって重要な判断要素になる。例えば、毎日外食をしたいユーザは、「繁華街のような賑やかな街にあるアパート」と「閑静な住宅街にあるアパート」を比べた時に「賑やかな街にあるアパート」を好むと考えられる。また、子連れのユーザにとっては「賑やかな街にあるホテル」は旅行先のホテルには適さない。このように、ユーザに馴染みのない場所における地物選択では周辺環境の把握が求められる。

しかし、Google マップ³等のオンライン地図を用いることで、周辺の駅やコンビニなどの地物との位置関係は分かるが、地域特性を把握できない場合がある。例えば、駅から徒歩1分のアパートであると把握できても、その地域が「賑やか」なのか「閑静」なのかは分からず、駅からすぐ近くならば繁華街であると予測できるが、小規模な駅であったり、周辺地物が少なかったりすると、駅周辺でも「閑静」な雰囲気である可能性も高い。このように、主要な周辺地物との距離だけでは地域特性を読み取ることは困難である。

本研究の目的は、ユーザの入力地物に対して、周辺の地域特性を自動的に予測する手法の開発である。地域特性の予測が可能になれば、ユーザにとって馴染みのない地域であっても、その土地の雰囲気を把握できる。

本研究では、地域特性の予測という目的のために、地理オブジェクトの位置関係や地物カテゴリが地域特性に影響すると仮

説を立てた。つまり、対象地物の周辺地物を分析することにより、その周辺が「賑やか」か「閑静」であるかといった地域特性を予測できると考える。そこで、本研究では地域特性付き地図画像データセットの学習により、地図上の地理オブジェクトのカテゴリと地物間の位置関係から地域特性を予測するプログラムを構築する。提案手法の流れを図1に示す。

学習する地図画像には、地物カテゴリの位置関係を可視化するため、カテゴリごとに地物をマッピングした地図画像を用いる。この地図画像は中心地物はマンションであり、中心から500m以内の範囲とする。この地図画像に対する正解ラベルは、そのマンションのレビュー中に現れる地域特性を表すキーワードの出現率とする。例えば、賑やかを表す「うるさい」などのキーワードの出現率により各地域特性の強さを表現する。それぞれの地図画像に対して、複数のキーワードの出現率をラベルとするため本研究の正解ラベルはマルチラベルとなる。

評価実験では、CNN を用いて、訓練データ400件からモデルを作成した。そして、テストデータ100件の地図画像に対してその地域内のマンションのレビューにおける地域特性を示すキーワードの出現率を予測した。その結果、キーワードの予測出現率から対象地域の特性を予測できた。

本論文の構成は次のとおりである。2章では関連研究と本論文との関連性について述べる。3章ではデータセットについて述べる。4章ではCNN を用いた地図画像の解析について述べる。5章では評価実験について述べる。最後に、6章ではまとめと今後の検討について述べる。

2 関連研究

2.1 地物検索

本研究は、地物検索に関する研究と深く関連する。従来の検索システムでは地物名や住所入力により、該当する地物を検索結果として標示する。そこで、ユーザの検索クエリを拡張し、潜在

1 : <https://suumo.jp/>

2 : <https://travel.rakuten.co.jp/>

3 : <https://www.google.com/maps/@24.154087,120.657415,15z?hl=ja>

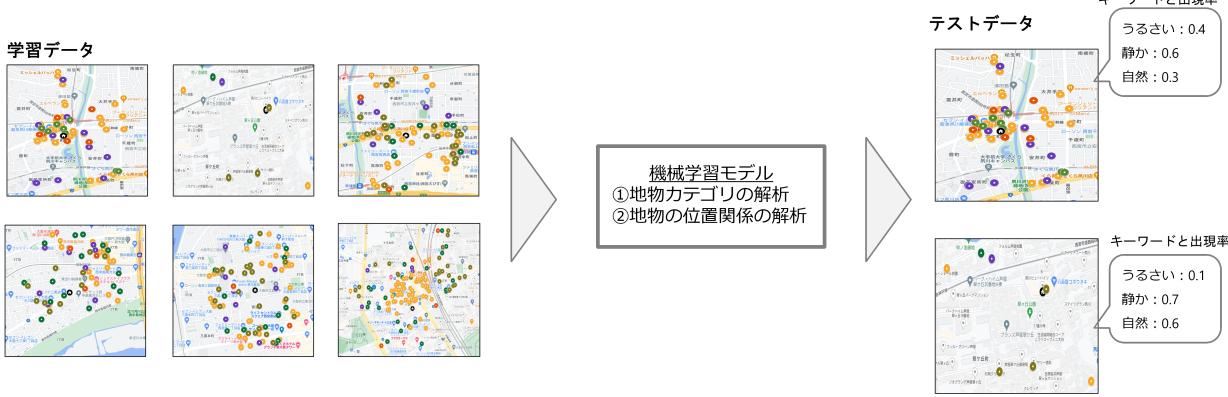


図 1 提案手法の概要

的な要求を満たす地物検索に関する研究が多く行われた。

前川ら [1] はユーザーの目的をクエリとする情報検索システムを提案している。「ギターの練習が出来る場所」というクエリに対して、単に音楽スタジオを推薦するのではなく、地物に対するレビューからギターを練習できる場所を読み取り、「公園」や「カラオケボックス」などを推薦する。レビューから特徴を読み取る点では本研究と類似する。

加藤ら [2] は例示検索による地物推薦システムを提案している。ユーザーに馴染みのある地域の地物を検索クエリとして入力することで馴染みのない地域においてもユーザーのクエリを満たす地物を推薦できる。ユーザーに馴染みのある地域において選択された例と選択されなかった例において差異を增幅することにより、ユーザーの潜在的なクエリを満たす地物を推薦できる。本研究は例示検索ではなく、地域特性から地物を検索する点で異なる。

2.2 地物間の関係性

本研究は、地物間の関係性を読み取る研究と深く関連する。嬉野ら [3] は地物同士の主観的な距離感覚を分析する手法を提案しており、マンションから何 m 以内にコンビニがあることが好ましいというユーザーの主観的な距離感覚を分析している。大塚ら [4] は異なる地物カテゴリ間の関係性を地物間の距離とレビューから分析している。例えば、温泉浴場とホテルは近いほど相互の影響度合いが大きいことが予測された。本研究は地図画像を解析することにより、地物間の距離だけでなく、地物間の位置関係にも着目している点でこれらの研究と異なる。

石綿ら [5] は都市における飲食店の地理的分布特性を把握するために、東京都を対象に、飲食店のカテゴリ別に GIS を用いて飲食店をマッピングし、飲食店のジャンルごとに密集する地域を可視化した。地理オブジェクトを地図上にマッピングする点は本研究と類似するが、本研究では飲食店に限定せず、カテゴリごとに地物をマッピングする。

我々はこれまでにホテルと周辺地物の地理関係をレビュー上の特徴語から予測した [6]。レビューは国立情報学研究所で提供されている楽天トラベル⁴のデータセットを使用し、特徴語は

頻出度と希少度に基づいて抽出した。頻出度に関しては、例えば、対象ホテルのレビューに「駅チカ」というキーワードが頻出すれば、対象ホテルには地理関係「駅チカ」があると仮定し、「駅直結」というキーワードが少なければ対象ホテルと駅には「直結」の関係が無いと仮定する。しかし、頻出度が小さくても、他のホテルには現れない地理関係であれば、それは重要な地理関係であると考えられる。そこで、各地理関係の頻出度に希少度を重みづけすることで、対象ホテルと周辺地物の特徴的な地理関係を予測した。評価実験の結果、1 対 1 の地物間の分布関係を予測することはできたが、地域特性を読み取ることはできなかった。その要因として、地域特性は複数の地物から構成されることが考えられる。そこで、本稿では、地図画像を分析することで、対象地域内の複数の地物のカテゴリや位置関係に基づいて地域特性を予測する。

2.3 地図画像解析

地図画像の解析に関して、山口ら [7] は、ユーザーの観光目的に応じた地図を提供するために、地図画像のクラス分類の性能を報告した。CNN を用いて与えられた地図画像を航空写真やグルメマップ、路線図など 10 種類のクラスに分類した。本研究では地図の種類を分類するのではなく、地図画像から地域特性を予測することを目的とする。

大野ら [8] は、国内の地物抽出評価用データセットが不足していることに着目し、衛星写真を対象に評価用データセットを構築した。また、Isola ら [9] は CGAN の一種である Pix2Pix を提案した。この手法により、入力画像から異なる画像の出力が可能になり、例えば衛星画像から地図画像を出力することができる。これらの研究と本研究は地理画像を対象にする点で類似しているため、モデルを構築する段階で参考にした。

3 データセットの構築

3.1 地図画像の学習データセット

本研究では、地域特性と地物のカテゴリ間には関連があると考える。例えば、居酒屋などのグルメカテゴリが密集する住宅街は「賑やかな街にある住宅街」である可能性が高く、周辺に地物が少ない住宅街であれば「閑静な街にある住宅街」である可

4 : <https://travel.rakuten.co.jp/>

能性が高い。また、地物の位置関係も地域特性に影響すると考える。そこで、本研究では地域特性を読み取るために、地図を入力とした機械学習モデルを構築する。一般的な地図では地物のカテゴリの区別がされておらず、地物カテゴリごとの位置関係を読み取ることは難しいため、本研究では地物をカテゴリごとにマッピングした地図画像を学習データに用いる。

3.1.1 地物カテゴリごとのマッピング

地物のマッピングに際して、地物カテゴリは Yahoo! ロコ⁵ のカテゴリ階層を参考にした。本研究で使用するカテゴリを表 1 に示す。

表 1 カテゴリと地物	
カテゴリ名	地物
グルメ	飲食店
日用品	スーパー・コンビニ
教育	小中高学校・保育園・幼稚園
交通	バス停・タクシー会社・駐車場
百貨店	ショッピングモール
病院	クリニック・総合病院

そして、Yahoo! ローカルサーチ API⁶ より地物の緯度経度を表 1 のカテゴリごとに抽出し、Google マイマップにて地物のカテゴリごとにピンをマッピングした。このとき、中心地物はマンションとして、中心から 500 M 以内の周辺地物をマッピングした。中心地物をマンションにする理由は 3.2 で述べる。

3.1.2 マッピングから予測できる地理的な特徴

先述した手順でマッピングした地図画像の例を図 2 に示す。この例では、阪急神戸線の夙川駅、十三駅周辺のマンションを中心とした地図をそれぞれ 3 つずつ提示している。ピンの種類は図 2 に示す通りである。また、地図画像のスタイルは Google マップ⁷ のデフォルトを使用する。ピンだけでなく背景の川や公園の緑、駅からも地域の特性を読み取る。例えば、図 2-1 からは、この地域には駅のすぐ近くを川が流れしており、その川沿いには緑が見られることが読み取れる。また、図 2-2 からは、地物が少なく、密度量が小さいエリアであることが分かり、図 2-6 からは地物の密度量が大きく、特に飲食店が密集する地域であることが読み取れる。このように、ピンのマッピングから地物カテゴリごとに地域内に存在する地物のカテゴリやその分布関係を読み取れるため、本研究ではこの地図画像を用いて深層学習を行う。

3.2 地域特性の抽出

次に、機械学習を行う際の正解ラベルに関して述べる。本研究ではレビュー中の地域特性を表すキーワードが出現する割合を正解ラベルとする。3.1.1 で述べたように本研究における地図画像は中心地物がマンションであるため、そのマンションのレビューから地域特性を表すキーワードの出現率を算出する。地域特性を表すキーワードの出現率により、そのマンション周辺

がどのような環境であるか読み取る。マンションのレビューデータにはマンションノート⁸ に投稿されたレビューを使用する。

3.2.1 地域特性

地域特性は多様であるが、本稿では代表的な地域特性として以下 10 種類を対象とする。以降では以下の記号を用いて各地域特性を示す。

- K_1) 賑やかな街：商業施設や飲食店が多く集まるエリア
- K_2) 閑静な街：静かで落ち着いたエリア
- K_3) 都市：商業施設や行政機関が立ち並ぶエリア
- K_4) 田舎：地物が少なく田畠が多いエリア
- K_5) 緑豊かな街：緑や川など自然が充実したエリア
- K_6) 子育てしやすい街：教育機関が充実したエリア
- K_7) 交通利便性が良い街：交通機関が充実したエリア
- K_8) 買い物しやすい街：生活用品を購入できる小売店が充実したエリア
- K_9) 食事に便利な街：飲食店が充実したエリア
- k_{10}) 安全な街：治安の安全に繋がる地物が充実したエリア

3.2.2 地域特性を示すキーワード

地図画像の地域が先述した 10 種類の地域特性のうち、どの地域特性に当てはまる可能性が高いか予測するために、その画像の中心地物であるマンションのレビューの頻出語に着目する。例えば、マンションのレビューにおいて「賑やか」を表すキーワードの出現率が「閑静」や「子育て」、「安全」など他の地域特性を表すキーワードの出現率よりも高ければ、そのエリアは「賑やか街」である可能性が高いと予測できる。そこで、本稿では、各地域特性を示すキーワードの出現率を地図画像に対するマルチラベルとする。各地域特性（賑やか・閑静・都市・田舎・自然豊か・子育て・交通・買い物・食事・安全）を示すキーワードに関しては、表 2 に示すキーワードを用いる。このキーワードは Wordnet より抽出した「各地域特性と類似するキーワード」と Word2Vec より抽出した「各地域特性と関連度が高いキーワード」の中から抜粋したものである。

表 2 カテゴリと地物

地域特性	地域特性を表すキーワード
賑やかな街	賑やか, うるさい, 騒がしい, 物騒
閑静な街	閑静, 静か, のどか
都市	都市部, 都市圏, 大都市, 市街地
田舎	田園, 地方, 一軒家, 山奥, 町外れ
自然豊かな街	自然, 自然環境, 水辺
子育てしやすい街	子育て, 育児, 子ども
交通利便性が良い街	交通機関, 交通網, 交通手段, 交通
買い物しやすい街	買い物, ショッピング, 買い出し
食事に便利な街	ランチ, ディナー, 朝食, 昼食, 夕食, 昼御飯, 晩御飯
安全な街	安全, 安心安全, 安全性, 快適

5 : <https://loco.yahoo.co.jp/>

6 : <https://developer.yahoo.co.jp/webapi/map/openlocalplatform/v1/localsearch.html>

7 : <https://www.google.com/maps/@24.154087,120.657415,15z?hl=ja>

8 : <https://www.mansion-note.com/>



図 2 学習画像の一例

3.2.3 地域特性を表す特徴量

前節で述べたように、本研究では、それぞれの地図画像のエリアの地域特性の強さをラベルとするため、本節では、その特徴量の算出方法について述べる。以下の式が算出式である。

$$P_K = \frac{t_i}{R} \quad (1)$$

ここで、 R はあるマンションに投稿された全てのレビュー数を示し、 t_i はそのレビューの中で地域特性 K_i を表すキーワードが現れるレビュー数を指す。マンション M に対する全体の口コミに対して、地域特性 K_i を示すキーワード t_i が占める割合を算出する。

4 CNN を用いた地図画像の学習

本研究では3章のラベル付きデータセットをCNNを用いて学習した。モデルの構成は、3つの畳み込み層と1つのプーリング層、そして全結合層というモデルを定義する。このモデルは、大野ら[10]の研究を参考にした。

CNNの実装には、Pythonのライブラリ Keras を用いる。入力画像のサイズは 256×256 ピクセル、epoch 数 20、バッチサイズ 8 とする。本評価実験では、先述した通り子育てを示す単語の出現率のみを予測するため出力層は 1 とする。また、学習画像の数が 100 枚では不十分であるため、Keras(TensorFlow) の ImageDataGenerator により画像の水増しを行う。具体的には、vertical-flip と horizontal-flip により画像を反転し、学習画像の枚数を拡大する。

5 評価実験

5.1 実験設定

提案手法の精度を評価するために、評価実験を行った。データセットには阪急神戸本線・阪神本線の路線沿いの地域を対象に、地図画像を 130 枚用意した。このうち、100 枚の画像を訓練画像、30 枚の画像をテスト画像とした。また、本評価実験では先述した 10 種類の地域特性の中でも対象地域の子育てのしやすさに着目し、地域内のマンションのレビューにおける「子育てを表すキーワードの出現率」を推定する。

評価実験では、提案手法による地図画像の解析手法を手法 1 として、他 3 つのタイプの画像を解析する手法をそれぞれ手法 2、手法 3、手法 4 として比較する。手法 2 は図は図 3-2 のようにカテゴリで色分けせずにピンをマッピングした地図の画像解析である。手法 3 は図 3-3 のように無地の背景にピンをマッピ



図 3 比較画像の一例

表 3 評価実験の結果 (対象地域：阪急神戸本線・阪神本線)

データ名	正解	手法 1	手法 2	手法 3	手法 4
テスト①	0.0455	0.0948	0.0521	0.0588	0.1796
テスト②	0.0800	0.0758	0.0319	0.1707	0.1667
テスト③	0.0952	0.1345	0.1184	0.2122	0.1079
テスト④	0.1429	0.1019	0.1678	0.1969	0.1857
テスト⑤	0.3000	0.1500	0.1275	0.2275	0.2188
テスト⑥	0.3088	0.2337	0.1995	0.1791	0.1190
テスト⑦	0.0877	0.0772	0.1472	0.1686	0.0924
テスト⑧	0.3878	0.1558	0.2083	0.0848	0.0804
テスト⑨	0.1591	0.1915	0.2443	0.2017	0.1599
テスト⑩	0.2766	0.2223	0.1939	0.1661	0.1967
テスト⑪	0.0750	0.1283	0.2038	0.2063	0.2299
テスト⑫	0.1429	0.0460	0.0923	0.1618	0.2176
テスト⑬	0.4595	0.4540	0.1608	0.0774	0.0443
テスト⑭	0.2353	0.0850	0.0988	0.1381	0.2013
テスト⑮	0.1429	0.2058	0.2249	0.1964	0.1730
テスト⑯	0.0625	0.1307	0.1736	0.2068	0.3308
テスト⑰	0.1579	0.3545	0.0435	0.3210	0.0420
テスト⑱	0.0370	0.1836	0.1766	0.1473	0.0699
テスト⑲	0.0010	0.0580	0.1894	0.1006	0.1591
テスト⑳	0.1030	0.2100	0.0522	0.1700	0.2091
テスト㉑	0.1324	0.5194	0.1229	0.3504	0.1882
テスト㉒	0.6579	0.0945	0.2110	0.0678	0.0434
テスト㉓	0.1071	0.1325	0.0675	0.2036	0.3881
テスト㉔	0.1557	0.1065	0.0573	0.3214	0.0609
テスト㉕	0.1325	0.0920	0.1190	0.1727	0.1132
テスト㉖	0.1096	0.1403	0.1894	0.2728	0.1016
テスト㉗	0.1667	0.3217	0.0869	0.1281	0.2599
テスト㉘	0.0566	0.0990	0.0516	0.2977	0.1530
テスト㉙	0.2143	0.0448	0.0591	0.3034	0.3010
テスト㉚	0.0189	0.0760	0.1463	0.1216	0.1127

グした地図の画像解析である。手法 4 は図 3-4 のような一般的な地図の画像解析である。これらの手法を比較することで、地図画像の解析から地域特性を発見するためには、ピンや地図の背景が効果的であるか検証する。

5.2 結 果

評価実験の結果を表 3 に示す。また、表 4 は正解値と各手法による予測値の二乗誤差を示す。値が小さいほど高い精度で予測できることを示す。

正解値との誤差の平均によると、画像解析の精度が最も高いのは手法 2 であることが分かった。また、手法 1 も手法 2 との差は限りなく小さく、手法 2 と同様に高い精度で予測値を出力で

表 4 正解値との誤差(対象地域:阪急神戸本線・阪神本線)

	手法1	手法2	手法3	手法4
テスト①	0.0024	0.0000	0.0002	0.0180
テスト②	0.0000	0.0023	0.0082	0.0075
テスト③	0.0015	0.0005	0.0137	0.0002
テスト④	0.0017	0.0006	0.0029	0.0018
テスト⑤	0.0225	0.0298	0.0053	0.0066
テスト⑥	0.0056	0.0120	0.0168	0.0360
テスト⑦	0.0001	0.0035	0.0065	0.0000
テスト⑧	0.0538	0.0322	0.0918	0.0945
テスト⑨	0.0011	0.0073	0.0018	0.0000
テスト⑩	0.0029	0.0068	0.0122	0.0064
テスト⑪	0.0028	0.0166	0.0173	0.0240
テスト⑫	0.0094	0.0026	0.0004	0.0056
テスト⑬	0.0000	0.0892	0.1459	0.1723
テスト⑭	0.0226	0.0186	0.0094	0.0012
テスト⑮	0.0040	0.0067	0.0029	0.0009
テスト⑯	0.0047	0.0123	0.0208	0.0720
テスト⑰	0.0387	0.0131	0.0266	0.0134
テスト⑱	0.0215	0.0195	0.0122	0.0011
テスト⑲	0.0032	0.0355	0.0099	0.0250
テスト⑳	0.0114	0.0026	0.0045	0.0113
テスト㉑	0.1498	0.0001	0.2331	0.0031
テスト㉒	0.3174	0.1997	0.3482	0.3776
テスト㉓	0.0006	0.0016	0.0093	0.0789
テスト㉔	0.0024	0.0097	0.0274	0.0090
テスト㉕	0.0016	0.0002	0.0016	0.0004
テスト㉖	0.0009	0.0064	0.0267	0.0001
テスト㉗	0.0240	0.0064	0.0015	0.0087
テスト㉘	0.0018	0.0000	0.0581	0.0093
テスト㉙	0.0287	0.0241	0.0079	0.0075
テスト㉚	0.0033	0.0162	0.0106	0.0088
平均二乗誤差	0.0247	0.0192	0.0378	0.0334
分散	0.0149	0.0090	0.0191	0.0194
p値		0.4965	0.0198	0.1538

きた。また、手法3と手法4も予測の精度は決して低くはないが、手法1・手法2と比べると低い結果となった。これらのことから、地物にピンをマッピングすることが地図から地域特性を予測するために有効な手法であると分かった。しかし、全体的に高い精度で予測できた要因として、訓練画像とテスト画像の地域が共に阪急神戸本線・阪神線沿いの地域と限定されていたことが考えられる。そのため、訓練画像と同じような地図画像がテスト画像にも含まれており、予測が安易であった。そこで、評価実験で用いたモデルを使用して、東急東横線沿いの地域30件対象にした追加の評価実験を行った。次節では、その結果について述べる。

5.3 テスト画像: 東急東横線

東急東横線沿いの地図画像30件に対し評価実験の結果を表5に示す。また、表6には正解値と各手法による予測値との誤差を示す。

正解値との誤差の平均によると、先述した評価事件と同様に手法2による予測値が最も高い結果となった。また、手法1・手法3においても高い精度で予測できた。一方で、手法4による予測の精度は低い結果となった。2つの評価実験から地図上のピンが画像解析から地域特性を予測するうえで有効だと考えられる。

表 5 評価実験の結果(対象地域: 東急東横線)

データ名	正解	手法①	手法②	手法③	手法④
テスト①	0.2468	0.2063	0.0706	0.0735	0.0685
テスト②	0.2373	0.0937	0.0890	0.1447	0.1494
テスト③	0.1475	0.1747	0.2451	0.1490	0.0858
テスト④	0.2759	0.2024	0.0559	0.0856	0.1004
テスト⑤	0.1667	0.1944	0.1286	0.0956	0.0656
テスト⑥	0.1607	0.2165	0.0642	0.1054	0.0888
テスト⑦	0.0000	0.1836	0.1124	0.1456	0.3006
テスト⑧	0.1837	0.1659	0.0863	0.1342	0.0619
テスト⑨	0.0417	0.2173	0.1373	0.1088	0.1113
テスト⑩	0.0370	0.2790	0.0430	0.1872	0.0779
テスト⑪	0.3333	0.0968	0.0340	0.1193	0.1475
テスト⑫	0.0800	0.2171	0.1842	0.1906	0.1046
テスト⑬	0.3171	0.1207	0.1575	0.0992	0.1071
テスト⑭	0.1026	0.1981	0.1672	0.1671	0.4108
テスト⑮	0.1282	0.2235	0.1423	0.1166	0.1458
テスト⑯	0.0417	0.2626	0.0917	0.1639	0.1621
テスト⑰	0.2308	0.1525	0.1725	0.0824	0.1782
テスト⑱	0.1591	0.1408	0.1059	0.1582	0.0808
テスト⑲	0.2259	0.1417	0.1058	0.0979	0.0722
テスト⑳	0.0827	0.0620	0.0378	0.0568	0.1213
テスト㉑	0.1545	0.1243	0.0737	0.0707	0.0980
テスト㉒	0.2103	0.1228	0.1412	0.0875	0.0926
テスト㉓	0.1398	0.3068	0.2511	0.1291	0.0894
テスト㉔	0.1121	0.1175	0.1234	0.1197	0.1903
テスト㉕	0.2424	0.1032	0.2105	0.1462	0.1126
テスト㉖	0.2054	0.1624	0.1509	0.0737	0.0752
テスト㉗	0.2423	0.0722	0.0989	0.0900	0.0986
テスト㉘	0.0168	0.1308	0.0807	0.0860	0.1458
テスト㉙	0.1497	0.1596	0.1395	0.1627	0.0441
テスト㉚	0.0541	0.0232	0.1247	0.0677	0.0908

また、提案手法と他の手法について有意的な差があるか2つの評価実験においてp値を求めた。p値が0.05以下を統計的に有意差があるとみなすと、表4から手法1と手法2については有意差が認められることが分かる。しかし、手法1と手法3、手法4については有意差は認められなかった。また、表6から東急東横線を対象にした評価実験では手法1と他のどの手法にも有意差は認められなかった。全体的に有意差が見られなかった要因として、サンプルサイズが小さかったことが考えられる。

5.4 考 察

本節は先述した2つの評価実験を通じた考察について述べる。まずは地物のカテゴリごとのマッピングと地図の背景が有効であった例についてである。これが顕著に表れた地図画像の例を図4に示す。図4の地域には教育機関を示す紫のピンが密集する部分があるため、その部分が「子育てのしやすさ」を予測するうえで重要な判断基準となったと考えらえる。また、地図の背景から公園が複数分布することが読みとれるため、子育てのしやすさに地図の背景が影響した予測できる。これらのことから、予測したい地域特性に関連するピンがマッピングされたり、地図の背景に地域特性を示しうる情報がある場合にはピンや背景が効果的であると考える。

次にカテゴリに関係なく全ての地物に同じピンをマッピングした手法2が有効な地域について図5を示す。図5を見ると全ての地物に同じピンをマッピングする手法が有効である地域は地物量が少ない地域と考察する。図5からこの地図画像の地域は他の地域と比べて地物量が少ないことが読み取れる。このことから、地物量が少ない地域では、カテゴリによる色の分布より

表 6 正解値との誤差 (対象地域: 東急東横線)

	手法1	手法2	手法3	手法4
テスト①	0.0016	0.0310	0.0300	0.0318
テスト②	0.0206	0.0220	0.0086	0.0077
テスト③	0.0007	0.0095	0.0000	0.0038
テスト④	0.0054	0.0484	0.0362	0.0308
テスト⑤	0.0008	0.0014	0.0051	0.0102
テスト⑥	0.0031	0.0093	0.0031	0.0052
テスト⑦	0.0337	0.0126	0.0212	0.0904
テスト⑧	0.0003	0.0095	0.0024	0.0148
テスト⑨	0.0308	0.0091	0.0045	0.0049
テスト⑩	0.0586	0.0000	0.0226	0.0017
テスト⑪	0.0559	0.0896	0.0458	0.0345
テスト⑫	0.0188	0.0109	0.0122	0.0006
テスト⑬	0.0386	0.0255	0.0475	0.0441
テスト⑭	0.0091	0.0042	0.0042	0.0950
テスト⑮	0.0091	0.0002	0.0001	0.0003
テスト⑯	0.0488	0.0025	0.0149	0.0145
テスト⑰	0.0061	0.0034	0.0220	0.0028
テスト⑱	0.0003	0.0028	0.0000	0.0061
テスト⑲	0.0071	0.0144	0.0164	0.0236
テスト⑳	0.0004	0.0020	0.0007	0.0015
テスト㉑	0.0009	0.0065	0.0070	0.0032
テスト㉒	0.0077	0.0048	0.0151	0.0139
テスト㉓	0.0279	0.0124	0.0001	0.0025
テスト㉔	0.0000	0.0001	0.0001	0.0061
テスト㉕	0.0194	0.0010	0.0093	0.0169
テスト㉖	0.0018	0.0030	0.0173	0.0169
テスト㉗	0.0289	0.0206	0.0232	0.0206
テスト㉘	0.0130	0.0041	0.0048	0.0166
テスト㉙	0.0001	0.0001	0.0002	0.0111
テスト㉚	0.0010	0.0050	0.0002	0.0013
平均二乗誤差	0.0150	0.0122	0.0125	0.0178
分散	0.0003	0.0003	0.0002	0.0006
p値		0.2218	0.1894	0.2838

もピンの分布自体の違ひの方が地域特性に影響する可能性がある。そのため、ピンの分布関係のみを表した手法2の方が、色の要素が加わる手法1・手法3よりも画像解析の精度が高かったと考える。

次に、カテゴリごとに異なったピンのマッピングが地域特性を予測するうえで負に働いた例について図6を示す。図6の地域はピンの密集部分が大きく2つに分かれている特徴的な分布関係であることが分かる。ピンの分布自体が特徴的な場合、学習データに同じようなピンの分布が見られる地図画像が少ないため予測が難しい傾向にある。これに加えて色による違いまで読み取るとなると、予測が極めて難しくなり、色付きのピンに対する予測精度が低い結果になった。

最後に全ての手法の精度が低い地域について図7を示す。図7から立地環境が特異な地域の場合、手法に関係なく地図から地域特性を予測することが難しいと考察した。図7の地域は左上部が全て水域であり立地環境が特徴的な地域と分かる。学習画像に同じような立地環境の地図が含まれておらず予測が難しかったと考えられる。

6 おわりに

本研究は地理オブジェクトの位置関係とカテゴリから地域特

性を予測することを目的とした。本稿では、CNNを用いて、学習する地図画像においてレビュー中の子育てを示すキーワードの出現率を推定した。学習データには、地理オブジェクトのカテゴリごとにマッピングした地図画像を使用し、正解ラベルは学習画像の中心地物であるマンションのレビュー中のキーワードの頻出率とした。訓練データ100件を用いて学習したところ、評価実験において比較的高い精度で予測することができた。

今後の課題として主に2点ある。1点目はピンをマッピングする際の地物のカテゴリについてである。本稿では6種類のカテゴリのみを対象にピンをマッピングしたが、yahoo!ロコのカテゴリ階層に従うと他にも30種類のカテゴリが存在する。それらのカテゴリに属する地物も地域特性の要因となることが考えられるため、ピンをマッピングするカテゴリの増加を検討する必要がある。しかし、そのカテゴリの中には交番のような生活に身近な地物が含まれる一方で、葬式場や結婚式場のような地域特性への関係が薄いと考えられる地物も含まれる。そのため、まずは、次元削減などを用いて地域特性に影響が強い地物のみを抽出する。2点目は、学習画像の増加である。現在は学習画像が100枚と不足していたことにより、学習できる地物分布が少なかった。その結果、特徴的な地物分布や立地環境にある地図画像に対して予測の精度が低くなった傾向がある。また、p値を見てもデータ数が少ないとにより手法間の有意差が認められなかった。そこで学習画像を増加するためにOpenStreetMapを用いて地理オブジェクトをマッピングした地図の作成を検討する。

謝 辞

本研究の一部は、令和4年度科研費基盤研究(B)(課題番号:19H04118)、令和4年度科研費基盤研究(B)(課題番号:22H03905)の助成を受けたものである。

文 献

- [1] 前川由依, 莊司慶行, Martin J. Durst. 地物間と単語間の類似度を考慮した目的をクリエイティブとする地物情報検索. DEIM2020 A5-2(2020).
- [2] 加藤誠, 大島裕明, 小山聰, 田中克己. 地域コンテキストを考慮した動的な特徴空間に基づく地理情報例示検索. 情報処理学会論文誌, Vol. 52, No. 12, pp. 3448–3460(2011).
- [3] 嬉野孝延, 北山大輔, 角谷和俊. 地物カテゴリ間の距離の集合に基づく地物表示制御. 第142回情報基礎とアクセス技術 Vol.2021-IFAT-142, No.12(2021).
- [4] 大塚公貴, 角谷和俊. 地物間の距離と関係性による地域特性分析. DEIM Forum 2019, P2-120(2019).
- [5] 石綿朋葉, 後藤晴彦, 吉江俊. 東京と区分における飲食店立地と食情報の地域特性に関する研究. 日本建築学会計画系論文集 第83巻, 第744号, 251-261(2018).
- [6] 福地湧, 牛尼剛聰, 角谷和俊. 地域特性を表現する概念と地理的特徴の関係性分析. 第21回情報科学技術フォーラム(2022).
- [7] 山口元氣, 桂井麻里衣. 機械学習を用いた地図画像の多クラス分類. 人工知能学会第二種研究会資料 SIG-SWO-047-11(2019).
- [8] 大野裕幸, 遠藤涼, 中埜貴元, 篠田昌子. 空中写真を用いた地物抽出性能評価用データセットの構築. JSAI2019(2019).
- [9] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, Alexei A. Image-to-Image Translation with Conditional Adversarial Networks. CVPR2017(2017).
- [10] 大野裕幸, 浦郁子. AIを活用した地物自動抽出に関する研究(第4年次). 国土地理院令和3年度調査研究年報, 180-183(2022).

図4 色分けしたピンと背景が有効な例

【評価実験(対象地域：阪急神戸本線・阪神線)テスト⑪】



【評価実験(対象地域：東急東横線) テスト①】

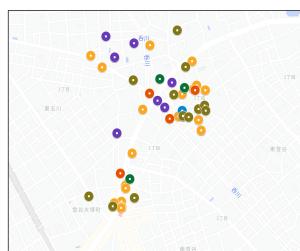
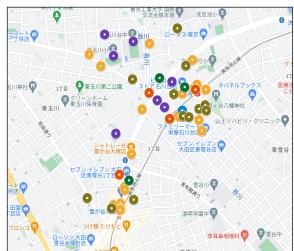
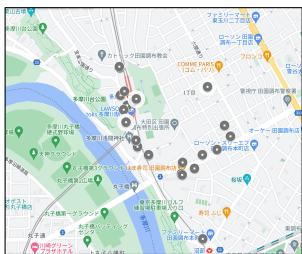
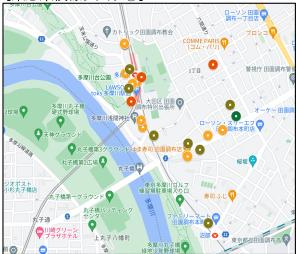


図5 カテゴリで色分けしない画像の予測精度が高い例

【東急東横線テスト⑯】

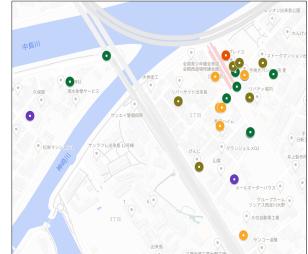


【東急東横線テスト⑰】



図 6 カテゴリごとに色分けした画像の予測精度が低い例

【阪急神戸本線・阪神線テスト②】



【東急東横線テスト⑩】



図 7 全てのタイプの画像の予測精度が低い例

【阪急神戸本線・阪神線テスト㉚】

